UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO ALBERTO LUIZ COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA DE ENGENHARIA – COPPE
PROGRAMA DE ENGENHARIA MECÂNICA – PEM

Proposta submetida ao

Edital FAPERJ nº 34/2026 – Programa de Apoio à Fixação de Doutores no Estado do Rio de Janeiro – Conhecimento Brasil / PROFIX-RJ (FAPERJ/CNPq/CAPES)

Otimização da composição química da água de injeção baseada em dados geológicos, geoquímicos e operacionais por algoritmos de aprendizado por reforço e redes neurais informadas pela física (PINNs) para preservação da injetividade

Proponente: **Ramon de Paoli Mendes**

Instituição executora	Universidade Federal do Rio de Janeiro (UFRJ)
Programa de Pós-Graduação	Programa de Engenharia Mecânica (PEM) – COPPE/UFRJ
Grande área / área / subárea	Engenharias / Engenharia de Petróleo / **[confirmar subárea oficial no SisFAPERJ]**
Eixo estratégico	Óleo e gás
Bolsa CAPES pleiteada	Doutorado (48 meses)
Duração	48 meses (+3 meses para indicação dos bolsistas CAPES)
Auxílio FAPERJ solicitado	R$ 200.000,00

Rio de Janeiro
Novembro de 2026

Sumário

Resumo . . . 1
1 Justificativa e diagnóstico da situação atual . . . 1
2 Estado da arte . . . 2
3 Trajetória do proponente e aderência ao projeto . . . 4
4 Questão científica, tecnológica ou de inovação e hipóteses . . . 4
5 Objetivos . . . 5
5.1 Objetivo geral . . . 5
5.2 Objetivos específicos . . . 5
6 Metodologia . . . 5
6.1 Formulação: decisão sequencial sob observação parcial . . . 5
6.2 Etapa 1 – Modelo físico do dano . . . 6
6.3 Etapa 2 – Análise de sensibilidade global . . . 7
6.4 Etapa 3 – Ensaios no LRAP+ e identificação por PINN inversa . . . 7
6.5 Etapa 4 – Modelo substituto . . . 7
6.6 Etapa 5 – Agente de aprendizado por reforço . . . 7
6.7 Quantificação de incerteza e critérios estatísticos . . . 8
6.8 Etapa 6 – Estimação em operação e validação com dados de campo . . . 9
6.9 Etapa 7 – Validação experimental da política e software . . . 9
7 Metas, entregas verificáveis e indicadores de acompanhamento . . . 10
7.1 Metas e entregas verificáveis . . . 10
7.2 Indicadores de acompanhamento . . . 10
8 Cronograma físico em meses corridos . . . 11
9 Resultados esperados . . . 11
9.1 Resultados científicos . . . 11
9.2 Resultados tecnológicos . . . 12
9.3 Formação e consolidação institucional . . . 12
9.4 Produção científica . . . 12
10 Riscos técnico-científicos e estratégias de mitigação . . . 12
11 Formação de recursos humanos . . . 13
12 Infraestrutura existente e necessária . . . 13
12.1 Infraestrutura existente . . . 13
12.2 Infraestrutura necessária . . . 13
13 Redes e colaborações nacionais e internacionais . . . 13
14 Impacto esperado e público beneficiado . . . 13
14.1 Impacto científico, tecnológico, social, econômico e ambiental . . . 13
14.2 Público beneficiado e impacto institucional . . . 14
15 Contribuição para o desenvolvimento do Estado do Rio de Janeiro . . . 14
16 Estratégia de integração e fixação institucional . . . 14
16.1 Inserção na instituição executora . . . 14
16.2 Linha de pesquisa a ser criada . . . 14
16.3 Infraestrutura disponibilizada . . . 14
16.4 Integração ao Programa de Pós-Graduação . . . 14
16.5 Plano de sustentabilidade após o término do apoio . . . 14
17 Plano de educação, comunicação, popularização e divulgação científica . . . 14
18 Estratégia de acesso, preservação e difusão dos resultados . . . 15
19 Orçamento detalhado e justificado . . . 15
20 Ética, integridade, biossegurança, propriedade intelectual e dados de pesquisa . . . 15
Referências . . . 16

Nomenclatura

Símbolos latinos

a_t	Ação no período t (composição, tratamento, dosagens, vazão e temperatura)
c	Concentração de partículas em suspensão [m^3/m^3]
c_i	Coeficiente de sensibilidade da grandeza de entrada x_i
c_{trat}, c_{bomb}, c_{int}	Custos de tratamento, de bombeamento e de intervenção na recompensa
C_{Ba}, C_{SO_4}	Concentrações de Ba^{2+} e $SO_4{}^{2-}$ [mol/kg]
ΔC_{prec}	Quantidade precipitada no passo de tempo [mol/kg]
d_t	Dano acumulado e sua distribuição radial
$\mathcal{D}$	Conjunto de dados experimentais e de campo
E_n	Erro normalizado (ISO 13528)
g_k	Restrições operacionais e de segurança
I, I_0	Índice de injetividade atual e inicial [$m^3/(s{\cdot}Pa)$]
k, k_0	Permeabilidade atual e inicial [m^2]; (k de abrangência em $U = k\,u_c$ é distinto)
K_{sp}	Produto de solubilidade do $BaSO_4$
L	Comprimento do meio poroso [m]
$\mathcal{L}$	Função de perda da PINN (termos de dados, EDP e contorno)
o_t	Condições operacionais no período t (pressões, temperatura, pressão do reservatório)
$p(\theta \mid \mathcal{D})$	Distribuição *a posteriori* dos parâmetros dado $\mathcal{D}$
ΔP, ΔP_0	Sobrepressão de injeção atual e inicial [Pa]
r_t	Recompensa no período t
R^2	Coeficiente de determinação
s_t	Estado do sistema no período t
SR	Razão de saturação
t, Δt	Tempo e passo de tempo [s]
T	Horizonte de decisão
u	Velocidade de Darcy [m/s]
$\hat{u}(x,t)$	Campos aproximados pela PINN (concentração, depósito e pressão)
u_A, u_B, u_{mod}, u_c	Incertezas padrão tipo A, tipo B, de modelo e combinada
U	Incerteza expandida
w_t	Composição das águas disponíveis no período t
x	Coordenada espacial [m]
x_{eq}	Quantidade termodinamicamente precipitável [mol/kg]

Símbolos gregos

α	Razão de injetividade, $\alpha = I/I_0 = \Delta P_0/\Delta P$
$\alpha_{\min}$	Razão de injetividade mínima antes de intervenção
β_p, β_{BaSO_4}	Coeficientes de dano à formação por partículas e por $BaSO_4$
γ_{Ba}, γ_{SO_4}	Coeficientes de atividade iônica
γ	Fator de desconto da recompensa (sem subscrito)
θ	Propriedades da rocha e do poço e parâmetros do dano
λ	Coeficiente de filtração [1/m]
λ_d, λ_r, λ_b	Pesos dos termos da perda da PINN
μ	Viscosidade da água [Pa·s]
π	Política do agente de RL
σ_p, σ_{BaSO_4}	Volume retido de partículas e de $BaSO_4$ por volume de rocha
τ, τ_{prec}	Tempo característico de precipitação [s]
ϕ, ϕ_0	Porosidade atual e inicial
ϕ_{NN}	Pesos da rede neural

Siglas e abreviaturas

ANP	Agência Nacional do Petróleo, Gás Natural e Biocombustíveis
CFL	Número de Courant–Friedrichs–Lewy
COPPE	Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia
CVaR	Valor em risco condicional
DeepONet	Rede de operadores profunda
EDP	Equação diferencial parcial
FAIR	Dados localizáveis, acessíveis, interoperáveis e reutilizáveis
FNO	Operador neural de Fourier
GUM	Guia para a expressão de incerteza de medição
IA	Inteligência artificial
IQM	Média interquartil
LRAP+	Laboratório de Recuperação Avançada de Petróleo
MD	Destilação por membrana
NF	Nanofiltração
PEM	Programa de Engenharia Mecânica
PINN	Rede neural informada por física
PPG	Programa de pós-graduação
PTFE	Politetrafluoroetileno (ePTFE: expandido)
RL	Aprendizado por reforço
SRP	Unidade de remoção de sulfato
UFRJ	Universidade Federal do Rio de Janeiro

Resumo

A reinjeção de água produzida, isoladamente ou misturada à água do mar tratada, é uma estratégia para a gestão da água e a manutenção da pressão em reservatórios de petróleo. Entretanto, a composição físico-química da água injetada pode comprometer a injetividade por mecanismos de dano à formação que interagem e evoluem ao longo do tempo, incluindo precipitação de incrustações minerais ($BaSO_4$, $CaCO_3$ e $SrSO_4$), migração e inchamento de argilas, retenção de partículas e gotículas de óleo, formação de reboco e atividade microbiológica. A intensidade desses fenômenos depende da mineralogia, das propriedades petrofísicas e da estrutura porosa da rocha, da composição das águas de formação, produzida e do mar, bem como das condições operacionais do poço. Apesar dessas interdependências, a especificação da água de injeção frequentemente se apoia em análises de compatibilidade e critérios de tratamento avaliados separadamente, sem incorporar plenamente o caráter cumulativo do dano.

Este projeto tem como objetivo desenvolver e validar uma metodologia computacional híbrida capaz de determinar e atualizar, ao longo da operação, as características físico-químicas e as condições de tratamento da água de injeção que melhor preservem a injetividade, respeitando restrições técnicas, econômicas e de segurança. A metodologia será organizada em sete etapas interdependentes: (i) desenvolvimento de um simulador físico de transporte reativo e evolução do dano à formação, com representação dos mecanismos geoquímicos, de retenção e de alteração da permeabilidade; (ii) análise de sensibilidade global e de identificabilidade para selecionar parâmetros dominantes e orientar os ensaios; (iii) realização de ensaios de *coreflooding* para identificação inversa, por PINNs, dos parâmetros físico-químicos e constitutivos que governam o dano à formação, com calibração do simulador e quantificação das incertezas; (iv) treinamento e validação de modelos substitutos (surrogate model) que reproduzam a resposta dinâmica do simulador com menor custo computacional; (v) treinamento e comparação de algoritmos de aprendizado por reforço (RL) para definir sequencialmente proporções de mistura entre fontes de água, composição iônica, salinidade, níveis de tratamento e condições de injeção, considerando os efeitos futuros das decisões; (vi) desenvolvimento e avaliação de um estimador de estados baseado em redes neurais informadas pela física (PINNs), com assimilação de dados operacionais de pressão, vazão e temperatura, para inferir a evolução dos mecanismos de dano à formação e quantificar as incertezas das estimativas; acoplamento desse estimador ao agente de aprendizado por reforço (RL), de modo que as decisões de composição, tratamento e injeção da água sejam atualizadas dinamicamente conforme o estado estimado do poço; e (vii) Validação experimental independente das políticas de otimização desenvolvidas por RL, mediante aplicação de diferentes sequências de composição e tratamento da água em ensaios de *coreflooding*, comparando seus resultados com estratégias convencionais.

A avaliação incluirá a propagação das incertezas dos parâmetros, testes em cenários geológicos e geoquímicos não utilizados no treinamento e análise estatística do desempenho das políticas. Esperam-se como resultados modelos físicos calibrados, parâmetros de dano com incertezas quantificadas, evidências sobre as vantagens e limitações da otimização adaptativa e um software aberto de apoio à decisão para recomendar composições, tratamentos e condições de injeção específicas a diferentes cenários de reservatório. Como impactos potenciais, destacam-se a redução da perda de injetividade, da demanda energética de bombeamento e da necessidade de intervenções corretivas, favorecendo o reaproveitamento da água produzida e a eficiência operacional de campos petrolíferos. A arquitetura do software preverá, adicionalmente, uma interface modular para futura integração com modelos externos de recuperação de petróleo utilizados pelas operadoras, permitindo considerar esse desempenho como objetivo adicional ou restrição, sem incluí-lo na validação experimental desta proposta.

Palavras-chave: injetividade; água de injeção; dano à formação; transporte reativo; redes neurais informadas pela física; aprendizado por reforço; otimização dinâmica.

1. Justificativa e diagnóstico da situação atual

A água produzida é o maior efluente líquido da produção de óleo e gás, com estimativa global superior a 250 milhões de barris por dia e volume crescente à medida que os campos amadurecem [1, 2]. É uma matriz formada pela água de formação e, em campos sob injeção, pela própria água injetada após a irrupção [3]. Sua reinjeção, isolada ou misturada à água do mar, é a destinação predominante em campos offshore maduros.

A composição dessa água define sua compatibilidade com o reservatório. Ela reúne eletrólitos monovalentes (Na^+, K^+, Cl^-), cátions divalentes formadores de incrustação (Ca^{2+}, Mg^{2+}, Ba^{2+}, Sr^{2+}, Fe^{2+}), ânions como ${SO_4}^{2-}$ e ${HCO_3}^-$ e gases dissolvidos como H_2S e CO_2 [4]. Quando a água injetada, rica em sulfato, encontra a água de formação rica em bário e estrôncio, a mistura ultrapassa o limite de solubilidade e precipita sulfatos, com destaque para o $BaSO_4$, cujo produto de solubilidade da ordem de 10^{-10} o torna praticamente irreversível depois de nucleado [5, 6]. A esse mecanismo somam-se a cristalização de halita em salmouras hipersalinas [7, 8], a transição gipsita–anidrita do $CaSO_4$ nas zonas de gradiente térmico [9], a migração de finos por redução de salinidade [10], a filtração profunda de sólidos e óleo [11] e o dano associado à atividade bacteriana.

O efeito integrado é a perda progressiva de permeabilidade no entorno do poço, com aumento do fator de película e queda do índice de injetividade [6, 12]. As consequências operam em três escalas: maior pressão de injeção e consumo elétrico das bombas; intervenções corretivas (acidificação, *scale squeeze*, *workover*) que retiram o poço de serviço e nem sempre restauram a permeabilidade original [13, 14]; e, a longo prazo, desbalanço da reposição de volume (*voidage replacement*), perda de pressão do reservatório e redução da recuperação final [3].

A relevância desse problema é particularmente evidente nos reservatórios offshore do estado do Rio de Janeiro, em que a reinjeção de água produzida e a utilização de água do mar tratada integram as estratégias de manejo de água e manutenção da pressão. Na Bacia de Campos, campos como Marlim, Albacora e Roncador apresentam condições em que a compatibilidade entre as águas injetadas e a água de formação é um aspecto importante da operação, especialmente diante do risco de precipitação de sulfatos de baixa solubilidade, como o $BaSO_4$ [7, 15]. Em reservatórios do pré-sal, a elevada salinidade de determinadas águas de formação e a necessidade de gerir volumes expressivos de água produzida ampliam a importância de definir critérios de tratamento e reinjeção compatíveis com as características de cada sistema rocha–fluido.

Na prática, a especificação da água de injeção pode envolver limites de concentração de sulfato e de outros íons formadores de incrustação, salinidade e composição iônica, pH, teor de sólidos suspensos e sua distribuição de tamanho, concentração de óleo residual, oxigênio dissolvido, atividade microbiológica e dosagens de produtos químicos, como inibidores de incrustação, biocidas e sequestrantes de oxigênio. Também são definidas condições de tratamento, proporções de mistura entre fontes de água e faixas operacionais de vazão, pressão e temperatura. Embora esses controles sejam necessários, o atendimento individual a limites de qualidade não assegura, por si só, a preservação da injetividade: águas que satisfazem especificações em seus pontos de origem podem tornar-se incompatíveis após a mistura com a água de formação; alterações na salinidade e na razão entre cátions podem favorecer o desprendimento ou o inchamento de argilas; e pequenas concentrações de partículas ou óleo podem produzir retenção cumulativa em rochas com gargantas de poros mais estreitas. Além disso, a precipitação mineral, a filtração profunda e a formação de reboco modificam a permeabilidade ao longo do tempo, de modo que uma condição inicialmente aceitável pode deixar de sê-lo à medida que o dano se acumula e a composição das águas disponíveis varia. Consequentemente, a análise isolada de parâmetros físico-químicos ou a aplicação de limites fixos não representa necessariamente as interações entre água, rocha e operação, nem identifica a melhor decisão para preservar a injetividade durante toda a vida do poço.

A natureza multivariável, não linear e dependente do histórico dos mecanismos de dano à formação exige abordagens capazes de integrar informações geoquímicas, geológicas, petrofísicas e operacionais, superando a definição de limites independentes para os parâmetros de qualidade da água de injeção. Nesse contexto, a combinação de modelos físicos e inteligência artificial oferece uma estratégia para representar as interações entre esses mecanismos e antecipar os efeitos de diferentes condições de injeção. As redes neurais informadas pela física (PINNs) podem incorporar as equações de conservação e transporte à análise de dados experimentais e operacionais, permitindo identificar parâmetros de dano de difícil medição direta e estimar estados internos do sistema, com avaliação de suas incertezas. Por sua vez, algoritmos de aprendizado por reforço (RL), treinados em um ambiente de simulação física calibrado e computacionalmente acelerado, podem avaliar sequências de decisões sobre composição química, mistura de águas, níveis de tratamento e condições operacionais, considerando tanto as restrições do processo quanto as consequências futuras do dano acumulado. O acoplamento entre a estimação de estados por PINNs e a otimização sequencial por RL possibilita atualizar as recomendações à medida que novas informações operacionais se tornam disponíveis. Espera-se, assim, estabelecer uma metodologia de apoio à decisão mais adaptativa e fundamentada fisicamente, com potencial para preservar a injetividade, reduzir o consumo energético de bombeamento e a necessidade de intervenções corretivas, e ampliar o aproveitamento da água produzida. A estrutura modular proposta também permitirá, em aplicações futuras, incorporar modelos externos de recuperação de petróleo, de modo que a preservação da injetividade possa ser conciliada com objetivos produtivos definidos por cada operadora, sem exigir o desenvolvimento de um simulador completo de recuperação neste projeto.

2. Estado da arte

Na literatura recente, a inteligência artificial (IA) aplicada à injeção de água de baixa salinidade ou composição ajustada (*low-salinity/engineered water injection*) concentra-se, em grande parte, na previsão de recuperação de petróleo a partir das interações entre água, rocha e óleo. Na revisão de Arain et al. [16], são discutidos mecanismos como troca iônica multicomponente, alteração de molhabilidade, dissolução mineral e migração de finos, bem como aplicações de redes neurais artificiais, máquinas de vetores de suporte e métodos baseados em árvores. A revisão ressalta que o efeito da salinidade não é universal: as respostas dependem da mineralogia, da composição iônica, das condições operacionais e do histórico de interação entre os fluidos e a rocha.

Shafiei et al. [17] compararam diferentes algoritmos para prever o desempenho da injeção de água de baixa salinidade em carbonatos, com base em dados experimentais, conforme sintetizado por Arain et al. [16]. Tatar et al. [18] avaliaram modelos orientados por dados em arenitos, incluindo variáveis de composição iônica e propriedades do sistema rocha–fluido. Kondori et al. [19] examinaram modelos conexionistas híbridos para estimar o desempenho da injeção de água de baixa salinidade, considerando, entre outros atributos, salinidade, vazão, temperatura e permeabilidade. Em todos esses casos, as variáveis químicas são relevantes, mas os indicadores preditos dizem respeito principalmente à recuperação de óleo, não à evolução do índice de injetividade causada pelo dano próximo ao poço.

A revisão de Arain et al. [16] também apresenta estudos apoiados em dados sintéticos produzidos por simuladores. Esse procedimento permite explorar espaços de parâmetros extensos, mas a precisão obtida sobre dados gerados pelo mesmo modelo não demonstra, por si só, capacidade de generalização para formações heterogêneas e

operações reais. Para o problema da injetividade, essa distinção é particularmente importante: prever corretamente o fator de recuperação não equivale a prever deposição mineral, desprendimento de finos, obstrução de gargantas de poros ou perda de permeabilidade em torno do injetor.

Partindo dessa capacidade preditiva, a pesquisa passou também a investigar a seleção computacional de condições de injeção mais favoráveis. Reginato et al. [20] aplicaram uma abordagem híbrida com agrupamento e redes neurais à previsão de alterações de permeabilidade relativa durante a injeção de água de composição ajustada em carbonatos, apoiando análises de desenvolvimento do reservatório. Mercado Sierra et al. [21] estudaram estratégias de injeção de água de baixa salinidade no campo de Namorado com simulação composicional e otimização sob incerteza geológica. Uma abordagem baseada em modelo substituto neural e otimização por enxame de partículas também foi considerada na seleção de salinidade, concentração de polímero e condições de injeção [22]. Nesses antecedentes, a composição da água integra o espaço de variáveis analisadas, porém a função objetivo está associada principalmente ao desempenho da recuperação ou a métricas econômicas.

Essa distinção não implica oposição entre recuperação e injetividade. Ao contrário, uma especificação operacionalmente útil deve minimizar o dano à formação sem desconsiderar os requisitos de produção do reservatório. O foco do presente projeto é a preservação da capacidade de injeção: a composição selecionada deve limitar precipitação de $BaSO_4$, $SrSO_4$ e outros sais, instabilidade de argilas, retenção de sólidos e óleo e os efeitos cumulativos desses processos. Diferentemente de uma busca estática pela melhor salinidade, a decisão poderá ser atualizada quando mudarem a composição das águas disponíveis, a operação ou o estado estimado de dano.

A aplicação operacional dessas estratégias depende, por sua vez, de representar adequadamente a heterogeneidade do reservatório e as condições efetivas dos poços. Nesse sentido, métodos de IA vêm sendo empregados para integrar observações geológicas estáticas e registros operacionais dinâmicos. Yuan et al. [23] desenvolveram, para um projeto de combustão *in situ* em Hongqian, Xinjiang, um modelo híbrido geológico–dinâmico de conectividade entre poços injetores e produtores. A abordagem combina similaridade entre perfis geofísicos, seleção de atributos por aprendizado de máquina e variáveis de operação e produção; sua avaliação foi confrontada com tendências de produção e ensaios com traçadores. O estudo trata de *injeção de ar e conectividade interpoços*, não de otimização da composição de água nem de incrustação. Seu interesse metodológico para esta proposta reside na integração de dados heterogêneos e na seleção de variáveis relevantes para caracterizar sistemas de reservatório.

Essa integração sugere uma extensão útil à avaliação da injetividade. Propriedades da rocha, perfis geofísicos, condições de completação e históricos de pressão e vazão contêm informações complementares, mas nem sempre permitem observar diretamente os depósitos e a evolução radial da permeabilidade. Torna-se necessário empregar modelos físicos e métodos de assimilação de dados que distingam, quando possível, alterações da pressão do reservatório e perdas de mobilidade de danos localizados no entorno do poço. A conectividade interpoços pode contribuir futuramente com o contexto operacional, sem substituir a caracterização dos mecanismos físico-químicos de dano.

Uma vez caracterizadas as condições físico-químicas e operacionais, a seleção da água deixa de ser apenas um problema preditivo e passa a exigir decisões ao longo do tempo. O aprendizado por reforço (RL) permite representar essas escolhas como uma sequência em que ações presentes afetam o estado e os resultados futuros. Estudos já investigaram algoritmos de RL para controlar vazões e coordenar operações de injeção e produção, incluindo abordagens com agentes múltiplos e modelos substitutos [24–26]. Essas aplicações demonstram o interesse de reduzir o custo de simulações repetidas e de considerar efeitos temporais na otimização; entretanto, nos trabalhos citados, a decisão principal se concentra na operação hidráulica ou produtiva, e não na seleção sequencial da composição iônica e das etapas de tratamento para prevenir dano à formação.

A combinação de simuladores de transporte reativo com modelos substitutos de aprendizado profundo é promissora nesse cenário. Um simulador físico pode representar transporte de espécies, precipitação, retenção de partículas e evolução da permeabilidade, enquanto um substituto treinado em simulações calibradas aproxima as transições de estado necessárias a numerosos episódios de RL. Sua utilização exige validação em cenários não vistos e verificações periódicas no simulador original, pois o agente pode explorar imprecisões do modelo substituto. A incerteza das previsões também precisa informar as restrições e a avaliação de segurança das ações recomendadas.

A eficácia da otimização sequencial depende ainda de identificar parâmetros de dano e inferir estados internos que não são medidos diretamente. Para esses problemas inversos, as redes neurais informadas pela física (PINNs) constituem uma alternativa em que dados experimentais ou operacionais são combinados a equações de conservação e transporte [27]. No projeto proposto, sua utilização será investigada em duas funções distintas: identificar parâmetros físico-químicos e constitutivos do dano a partir de ensaios de *coreflooding*; e investigar a estimação de estados não diretamente observáveis a partir de históricos de pressão, vazão e temperatura, com assimilação de dados. As estimativas e suas incertezas serão fornecidas ao agente de RL para condicionar a atualização das decisões ao estado provável do poço. A viabilidade dessa etapa depende da identificabilidade dos mecanismos e será comparada a métodos convencionais de calibração e assimilação, especialmente em regimes com frentes abruptas ou dados escassos.

Em conjunto, os trabalhos examinados demonstram avanços em três direções complementares: (i) previsão por IA dos efeitos da salinidade e da composição iônica sobre propriedades de fluxo e recuperação de petróleo;

(ii) otimização computacional de variáveis químicas e operacionais com foco sobretudo em recuperação ou retorno econômico; e (iii) integração de dados geológicos e operacionais e aplicação de RL a decisões sucessivas de injeção e produção. Entretanto, os estudos aqui analisados não estabelecem uma metodologia experimentalmente validada que selecione *ao longo do tempo a composição físico-química, as proporções de mistura e os níveis de tratamento da água*, tendo como objetivo explícito a *preservação da injetividade* e considerando conjuntamente os mecanismos acumulativos de dano e a incerteza sobre o estado do poço. Essa constatação delimita a lacuna na literatura examinada, sem constituir afirmação de inexistência absoluta de abordagens correlatas.

A contribuição proposta é integrar um simulador físico de transporte reativo e dano à formação, PINNs para identificação de parâmetros e estimação de estados, um modelo substituto para acelerar a simulação e algoritmos de RL com restrições para otimização dinâmica da água de injeção. O ganho da decisão sequencial será comparado com especificações convencionais, composições fixas e reotimização periódica, com avaliação experimental independente por *coreflooding*. A arquitetura será modular e oferecerá uma interface para futura integração com simuladores de recuperação de petróleo das operadoras, desde que estes sejam sensíveis à composição da água. Essa extensão poderá permitir a otimização conjunta de injetividade, recuperação e custos, mas não constitui objeto da validação experimental prevista neste projeto. A revisão bibliográfica sistematizada em Scopus, Web of Science e OnePetro será utilizada para aprofundar e atualizar a delimitação dessa originalidade.

3. Trajetória do proponente e aderência ao projeto

A formação do proponente, integralmente realizada na Universidade Federal de Minas Gerais (UFMG), da graduação em Engenharia Mecânica ao doutorado, e a atuação posterior na COPPE/UFRJ reúnem três competências que este projeto integra: experimentação em sistemas termofluidos, inteligência artificial aplicada ao controle de sistemas dinâmicos e tratamento de água de produção na indústria de óleo e gás. Cada etapa dessa trajetória acrescentou um elemento à metodologia aqui proposta.

A base experimental foi construída no mestrado, dedicado à investigação do coeficiente de transferência de calor na condensação do fluido refrigerante de baixo impacto ambiental R1234yf. O trabalho exigiu projetar e operar uma bancada instrumentada, tratar dados experimentais e avaliar a incerteza de medição das grandezas derivadas, competências que agora sustentam o desenho dos ensaios de *coreflood* (etapas 3 e 7) e o tratamento metrológico dos parâmetros identificados (Seção 6).

No doutorado, o foco passou da medição à decisão. A pesquisa desenvolveu estratégias de controle de máquinas térmicas em que algoritmos preditivos de inteligência artificial determinam os ganhos do controlador a partir do comportamento previsto do sistema. A questão central já era a mesma que este projeto retoma em outro domínio: como um modelo aprendido a partir de dados pode orientar decisões sucessivas sobre um sistema não linear, cuja resposta depende do histórico de operação. O aprendizado por reforço proposto representa a extensão natural dessa linha, pois, em vez de ajustar os ganhos de um controlador, o agente aprende diretamente a política de decisão sobre a composição, o tratamento e a vazão da água de injeção, considerando os efeitos futuros de cada ação.

O contato com o problema da injetividade veio com o pós-doutorado no Programa de Engenharia Mecânica da COPPE/UFRJ, iniciado em 2024 e voltado ao tratamento de água de produção por membranas e ao desenvolvimento dos sistemas de controle desses processos, com um artigo sobre um *framework* de seleção de membranas atualmente em revisão. Essa atuação levou a pesquisa para a área de óleo e gás e evidenciou uma questão que o tratamento, isoladamente, não resolve: qual água deve ser injetada para preservar a injetividade do poço ao longo de sua vida útil. Por essa razão, o tratamento por membranas aparece neste projeto como uma das ações disponíveis ao agente (OE6), o que mantém a nova linha articulada à pesquisa em curso.

A proposta resulta, portanto, da convergência dessas três frentes e inaugura uma linha de pesquisa própria, na qual a experiência em medição e incerteza orienta os ensaios, a experiência em controle baseado em inteligência artificial fundamenta o agente de decisão e a atuação em tratamento de água de produção define o espaço de ações e o problema de aplicação. A produção científica completa consta do Currículo Lattes anexado.

4. Questão científica, tecnológica ou de inovação e hipóteses

Questão: é possível determinar, de forma adaptativa ao longo da vida do poço, as condições ótimas da água de injeção (composição, nível de tratamento e vazão) que preservam a injetividade, dadas as propriedades da rocha, as águas disponíveis (formação, produzida e do mar) e as condições operacionais, mesmo quando parte dos parâmetros que governam o dano não é medida diretamente?

Hipótese 1 (identificabilidade). Os parâmetros do dano que não são medidos rotineiramente (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas de desprendimento de finos) são identificáveis a partir de ensaios de deslocamento com tomadas de pressão intermediárias, análise do efluente e microtomografia, por meio de redes neurais informadas por física (PINN) em formulação inversa; o modelo calibrado prevê ensaios não usados na calibração com erro inferior a 15% [28].

Hipótese 2 (científica). A injetividade de poços injetores pode resultar de mecanismos de dano acoplados (incrustação, migração de finos, filtração, dano biológico), cuja resposta depende conjuntamente da composição da água, das propriedades da rocha (mineralogia, teor de argilas, estrutura porosa) e das condições operacionais (vazão, pressão e temperatura), e é cumulativa ao longo do tempo. Consequentemente: (a) as condições ótimas da

água não podem ser definidas por limites independentes para cada parâmetro, como fazem os critérios empíricos atuais; e (b) uma política de RL condicionada ao estado da rocha, da operação e do dano acumulado preserva a injetividade de forma significativamente superior à reotimização periódica míope, que escolhe a cada período a melhor condição para o momento atual sem considerar suas consequências futuras.

Critérios de refutação: (a) se condições definidas por limites independentes atingirem desempenho equivalente ao da política, o acoplamento entre mecanismos não é relevante na prática; (b) se a política não superar a reotimização míope em pelo menos 5% [29] nos cenários avaliados, a dependência da trajetória não é relevante, e a otimização estática periódica é suficiente.

Hipótese 3 (validação experimental). A política obtida no ambiente de simulação, transposta para a escala de laboratório, preserva a injetividade medida em coreflood melhor que as estratégias de referência, e o ambiente prevê a injetividade medida com erro inferior a 15% [28]. *Critério de refutação:* se a ordenação medida das sequências diferir da prevista, ou o erro exceder 15%, o ambiente não é confiável para decidir fora da faixa em que foi calibrado.

As hipóteses são encadeadas: a Hipótese 1 fornece parâmetros calibrados e sua incerteza; a Hipótese 2 usa esses parâmetros para testar o valor da decisão sequencial; a Hipótese 3 verifica em ensaios se as decisões tomadas em simulação se sustentam no meio poroso real. Se a Hipótese 1 for apenas parcialmente confirmada, a Hipótese 2 continua testável, com incerteza paramétrica maior incorporada ao treinamento do agente.

5. Objetivos

5.1 Objetivo geral

Desenvolver e validar uma metodologia que combine modelagem física do dano à formação, identificação de parâmetros por redes neurais informadas por física e aprendizado por reforço profundo para determinar dinamicamente as condições ótimas da água de injeção, incluindo sua composição química e a vazão de injeção, de modo a mitigar a incrustação, a migração de argilas e os demais mecanismos de dano que comprometem a injetividade, e validar experimentalmente essas decisões em ensaios de coreflood. A ferramenta será estruturada de maneira modular, com interfaces para possível acoplamento futuro a modelos externos de recuperação de petróleo, de forma a incorporar objetivos produtivos específicos sem ampliar o escopo de validação do presente projeto.

5.2 Objetivos específicos

OE1. Construir uma base de dados integrada de composição de águas, propriedades de rocha, variáveis operacionais e injetividade, a partir da literatura, de dados públicos de campo e dos ensaios do projeto.

OE2. Desenvolver um simulador radial multiespécie do dano (incrustação, finos e argilas, filtração e reboco, dano biológico), capaz de separar o dano real da queda aparente por pressurização do reservatório.

OE3. Realizar análise de sensibilidade global do simulador para identificar os parâmetros que mais afetam a injetividade e a decisão, e definir um conjunto mínimo de caracterização por rocha.

OE4. Projetar e executar ensaios de deslocamento no LRAP+ e identificar os parâmetros não medidos por PINN em formulação inversa, com quantificação de incerteza e validação cega (teste da Hipótese 1).

OE5. Desenvolver um modelo substituto informado por física, parametrizado pelas propriedades da rocha, pelas condições operacionais e pelas ações, que sirva de ambiente rápido de treinamento.

OE6. Treinar um agente de RL com restrições, robusto à incerteza paramétrica, que determine ao longo da vida do poço a composição, o tratamento (incluindo membranas de ePTFE/PTFE) e a vazão de injeção, e compará-lo com as referências definidas (teste da Hipótese 2).

OE7. Desenvolver um estimador do dano em operação, alimentado por dados de pressão e vazão de poços, e testá-lo com dados públicos de campo.

OE8. Validar a política em ensaios de coreflood no LRAP+ e disponibilizar simulador, modelos e agentes como software aberto de apoio à decisão, com interface modular documentada para eventual integração futura de modelos externos de recuperação de petróleo (teste da Hipótese 3 limitado à injetividade).

6. Metodologia

A metodologia é organizada em sete etapas encadeadas: simulação física (1), sensibilidade (2), calibração experimental por PINN inversa (3), modelo substituto (4), treinamento e avaliação dos agentes acoplados ao ambiente de simulação (5), estimação com dados de campo (6) e validação experimental da política com desenvolvimento do software (7). O trabalho é computacional, exceto as duas campanhas de coreflood no LRAP+ (etapas 3 e 7). A Figura 1 resume os fatores considerados e sua relação com o ciclo de decisão.

6.1 Formulação: decisão sequencial sob observação parcial

A escolha da água é formulada como um processo de decisão de Markov parcialmente observável. Em cada período t (dias a semanas), o estado do sistema é

$$s_t = (\theta,\ w_t,\ o_t,\ d_t)\,, \tag{1}$$

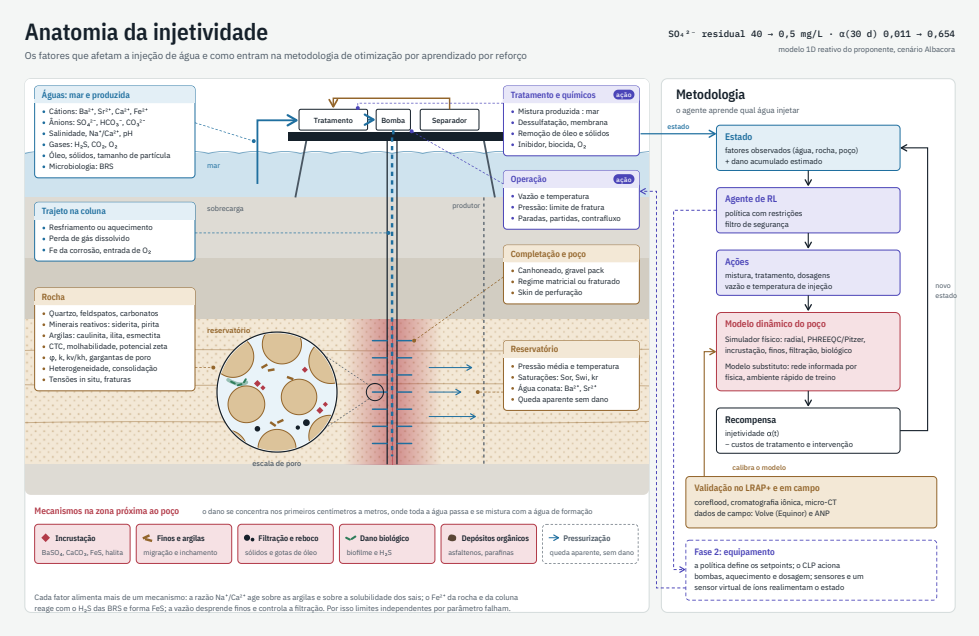


Figura 1: Fatores que afetam a injetividade, desde as fontes de água até a escala de poro, e sua relação com a metodologia: os fatores formam o estado do agente, as decisões sobre a água formam as ações, o modelo dinâmico do poço calcula o dano e a injetividade retorna como recompensa.

em que θ reúne as propriedades da rocha e do poço (mineralogia, tipo e teor de argilas, capacidade de troca catiônica, porosidade, permeabilidade, distribuição de gargantas, completação) e os parâmetros do dano; w_t, a composição das águas disponíveis (cátions, ânions, salinidade, pH, gases dissolvidos, óleo, sólidos e atividade microbiológica); o_t, as condições operacionais (pressões de cabeça e de fundo, temperatura, pressão média do reservatório); e d_t, o dano acumulado e sua distribuição radial. Parte de θ e todo d_t não são observados diretamente e são estimados (etapas 3 e 6).

A ação a_t define as condições da água injetada: razão de mistura entre água produzida e água do mar, grau de dessulfatação, tratamento por membrana, salinidade e razão $\mathrm{Na}^+/\mathrm{Ca}^{2+}$, remoção de óleo e sólidos, dosagens de inibidor, biocida e sequestrante de oxigênio, vazão e temperatura de injeção. A recompensa combina a manutenção da injetividade com os custos:

$$r_t = \alpha(t) - c_{\mathrm{trat}}(a_t) - c_{\mathrm{bomb}}(\Delta P_t) - c_{\mathrm{int}}\,\mathbb{1}[\alpha(t) < \alpha_{\min}], \tag{2}$$

e o agente busca a política π que maximiza o retorno esperado sob as restrições $g_k(s_t, a_t) \le 0$:

$$\max_{\pi}\ \mathbb{E}_{\theta\sim p(\theta|\mathcal{D})}\ \mathbb{E}_{\pi}\left[\sum_{t=0}^{T}\gamma^t r_t\right] \quad \text{s.a.} \quad g_k(s_t, a_t) \le 0. \tag{3}$$

As restrições g_k incluem índices de saturação, salinidade e velocidade críticas para estabilidade das argilas, pressão de fratura (manutenção do regime matricial), faixa de vazão compatível com a reposição de volume do reservatório e limites do equipamento de tratamento. A esperança sobre $p(\theta \mid \mathcal{D})$ incorpora a incerteza dos parâmetros identificados na etapa 3. A vazão é variável de decisão do ponto de vista do dano no entorno do poço; a vazão total do campo permanece como restrição externa. Nesta pesquisa, a recompensa se limita à preservação da injetividade e aos custos e restrições associados. Uma interface de acoplamento será definida para que, em aplicação futura, modelos de recuperação de petróleo de terceiros possam fornecer uma métrica adicional de desempenho ou uma restrição produtiva. Tal extensão exigirá modelos capazes de representar a influência da composição da água sobre a recuperação, compatibilidade entre as escalas temporais e validação própria; não integra o treinamento nem a avaliação experimental previstos neste projeto.

6.2 Etapa 1 – Modelo físico do dano

O simulador parte das formulações clássicas de filtração profunda [11, 30] e de precipitação de sulfatos em misturas de águas incompatíveis [6] e incorpora: (i) geometria radial no entorno do poço, com completação canhoneada ou em poço aberto; (ii) química multiespécie via PHREEQC com modelo de Pitzer ($BaSO_4$, $SrSO_4$, $CaSO_4$, $CaCO_3$, halita e FeS), incluindo a variação de temperatura e pressão ao longo da coluna e o aporte de ferro por corrosão; (iii) cinética de precipitação de segunda ordem na supersaturação [31], com tempo de indução; (iv) migração e inchamento de argilas em função da salinidade, da composição catiônica e da velocidade; (v) filtração profunda e

reboco externo de sólidos e gotas, dependentes da razão entre o tamanho das partículas e o das gargantas [11, 30]; (vi) módulo de dano biológico; e (vii) acoplamento com um modelo simplificado de reservatório, para separar o dano no entorno do poço da queda aparente de injetividade por aumento da pressão média e redução de mobilidade. O simulador é verificado por balanço de massa e por reprodução de casos da literatura.

6.3 Etapa 2 – Análise de sensibilidade global

Antes dos ensaios, o simulador é submetido a uma triagem de Morris [32] seguida de índices de Sobol [33] sobre os parâmetros não medidos e as condições de rocha e operação. Além de $\alpha(t)$, são analisadas saídas relevantes para a decisão: a ordenação de águas candidatas e as curvas de decisão (por exemplo, o sulfato residual máximo para manter $\alpha \geq 0{,}8$). Os resultados definem quais parâmetros precisam ser calibrados, quais podem ser fixados em valores de literatura, qual o conjunto mínimo de caracterização por rocha e quais variáveis podem ser retiradas do estado do agente.

6.4 Etapa 3 – Ensaios no LRAP+ e identificação por PINN inversa

Desenho dos ensaios. Antes de cada campanha, uma análise de identificabilidade (perfis de verossimilhança sobre dados sintéticos do simulador) define quais medições distinguem os parâmetros de interesse. Sabe-se, por exemplo, que a queda de pressão total não separa o coeficiente de filtração do coeficiente de dano, o que exige tomadas de pressão intermediárias [30]. Os ensaios serão realizados em plugs de arenito de afloramento análogo e, quando disponíveis, de reservatório, caracterizados por porosidade e permeabilidade (DV-4000), microtomografia e mineralogia (DRX e MEV, serviço externo), com salmouras sintéticas de composição controlada. As campanhas isolam um mecanismo por vez (compatibilidade e incrustação; redução escalonada de salinidade e testes de vazão crítica para finos; injeção de suspensões calibradas para filtração) e depois os combinam. Em cada ensaio são registrados vazão, diferencial de pressão total e, quando o porta-testemunho permitir, em tomadas intermediárias, concentrações no efluente por cromatografia de íons ao longo do tempo e microtomografia antes e depois, com replicatas nas condições prioritárias. Esta é a primeira de duas campanhas: seus ensaios são divididos em um conjunto de calibração e um de teste cego da Hipótese 1; a segunda campanha é dedicada à validação da política (etapa 7).

PINN inversa. Uma rede neural representa os campos de concentração, de depósito e de pressão $\hat{u}(x,t)$ e é treinada para satisfazer simultaneamente os dados e as equações do modelo [27]:

$$\mathcal{L}(\phi_{\mathrm{NN}}, \theta) = \lambda_d \, \mathcal{L}_{\mathrm{dados}} + \lambda_r \, \mathcal{L}_{\mathrm{EDP}} + \lambda_b \, \mathcal{L}_{\mathrm{contorno}}, \tag{4}$$

em que os parâmetros desconhecidos θ (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas) são variáveis treináveis. Onde a forma da lei constitutiva é incerta, como $k(\sigma)$, uma pequena rede aprende a própria relação. A incerteza é estimada por conjuntos de redes ou formulação bayesiana, resultando em $p(\theta \mid \mathcal{D})$. Como PINNs têm dificuldade com frentes abruptas em transporte em meios porosos [34], serão usadas ponderação adaptativa das perdas, treinamento progressivo no tempo e difusão artificial controlada, e os resultados serão comparados com a calibração clássica por mínimos quadrados sobre o simulador de volumes finitos.

Validação cega (Hipótese 1). Os ensaios são divididos em um conjunto de calibração e um conjunto de teste, com composições e vazões diferentes. O modelo calibrado prevê o conjunto de teste sem novo ajuste, e compara-se a injetividade, o perfil de depósito na microtomografia e a composição do efluente.

6.5 Etapa 4 – Modelo substituto

O agente exige milhares de episódios, o que torna inviável usar o simulador completo como ambiente. Será treinado um operador neural (DeepONet ou FNO) [35, 36], com resíduo físico na função de perda, que recebe θ, o estado e a sequência de ações e devolve a evolução do dano e de $\alpha(t)$. Os dados de treino são gerados pelo simulador, com amostragem por hipercubo latino sobre $p(\theta \mid \mathcal{D})$ e sobre o espaço de operação. A validação usa simulações não vistas, com metas de R^2, erro em α e ganho de tempo de avaliação, e a incerteza do substituto é estimada por conjunto de redes, para que o agente evite regiões em que o substituto não é confiável.

6.6 Etapa 5 – Agente de aprendizado por reforço

O agente é treinado sobre o substituto, com verificação periódica no simulador completo. Como nenhum algoritmo é superior em todos os problemas, serão avaliadas as oito famílias de aprendizado por reforço, cada uma com um papel definido no projeto (Tabela 1).

A avaliação é feita em dois estágios, para que a comparação ampla caiba no orçamento computacional:

(a) *Triagem:* um ou dois representantes de cada família são treinados em um ambiente reduzido (horizonte curto, menos cenários, três sementes). Na versão discretizada, o desempenho é normalizado pelo ótimo exato da iteração de valor. Os critérios para avançar são o retorno normalizado, a taxa de violação de restrições, a eficiência amostral (retorno por chamada ao simulador) e o custo computacional.

(b) *Aprofundamento:* os três ou quatro melhores da triagem, mais o PPO com restrições como referência fixa, seguem para o protocolo estatístico completo da Seção 6.7.

Os métodos multiagente e hierárquicos são avaliados nos cenários em que se aplicam (vários poços e várias variáveis de tratamento), e os métodos *offline* são avaliados por avaliação fora da política sobre históricos simulados e

Tabela 1: Famílias de algoritmos de RL avaliadas, seu uso no projeto e aplicações de referência.

Família e algoritmos	Uso no projeto	Aplicações
Tabulares: iteração de política e de valor, Monte Carlo, TD(0), TD(λ), SARSA, Q-learning	Versão discretizada e reduzida do problema (poucas águas candidatas, estados agregados). A iteração de valor fornece o ótimo exato dessa versão, usado como gabarito para verificar os métodos profundos.	[37–40]
Valor com redes neurais: DQN, Double DQN, C51, QR-DQN, Rainbow	Ações discretas (catálogo de águas e de níveis de tratamento). As versões distribucionais (C51, QR-DQN) estimam a distribuição do retorno e permitem políticas sensíveis a risco, avaliadas pelo CVaR.	[41–43]
Gradiente de política: REINFORCE, gradiente natural, TRPO	Referências de base para ações contínuas; o TRPO fundamenta a otimização com restrições por região de confiança (CPO) [44].	[45, 46]
Ator-crítico: A2C, A3C, DDPG, TD3, SAC, PPO	Candidatos principais para ações contínuas (proporções de mistura, dosagens, vazão), em versões com restrições por multiplicadores de Lagrange [47].	[48–55]
Baseados em modelo: Dyna-Q, PILCO, PETS, MBPO, Dreamer, MuZero	Usam o substituto para gerar transições e reduzir chamadas ao simulador. PILCO e PETS são eficientes quando cada amostra é cara, como no ajuste ao ambiente em escala de laboratório (etapa 7); o Dreamer, com modelo latente, trata a observação parcial.	[56–59]
Multiagente: Q-learning independente, MADDPG, VDN, QMIX, MAPPO	Dois usos: vários poços injetores que compartilham a capacidade de tratamento; e um agente por variável de tratamento (mistura, dessulfatação, dosagens), coordenados.	[60–63]
Offline: BCQ, CQL, IQL, AWAC, TD3+BC	Aprendizado a partir de históricos de operação já registrados, sem experimentação no poço; política inicial conservadora.	[64, 65]
Hierárquicos: opções, MAXQ, HIRO	Correspondem à hierarquia do problema: o nível alto escolhe a água (dias a semanas) e o nível baixo ajusta vazão e dosagens dentro de cada período.	[66–69]

públicos. Cada algoritmo é testado com observação completa e em versão recorrente (LSTM), e os hiperparâmetros são ajustados com o mesmo orçamento para todos, usando bibliotecas de referência (Stable-Baselines3, OmniSafe e d3rlpy). A robustez à incerteza é obtida sorteando $\theta \sim p(\theta \mid \mathcal{D})$ a cada episódio, de modo que a política funcione em toda a faixa plausível dos parâmetros, e não apenas no valor médio [70]. A observação parcial é tratada fornecendo à política a estimativa do estado latente produzida pelo estimador da etapa 6, ou por meio de uma política recorrente. Um filtro de segurança projeta as ações propostas na região viável definida pelas restrições g_k. O tratamento por membranas de ePTFE/PTFE entra como ação, com custo energético associado ao aproveitamento de calor residual.

Para testar a Hipótese 2, a política é comparada, nos mesmos cenários de rocha, água e operação, com três referências: (i) os critérios empíricos atuais, baseados em limites independentes por parâmetro; (ii) a melhor condição fixa para todo o horizonte, obtida por otimização bayesiana; e (iii) a reotimização periódica míope, em que a otimização bayesiana é reaplicada a cada período com as condições do momento. A referência (iii) é a principal, pois isola o ganho atribuível à antecipação das consequências futuras. As métricas são a injetividade média e final no horizonte, o custo total, o número de violações de restrição e a ordenação das alternativas. O protocolo estatístico de comparação está na Seção 6.7.

6.7 Quantificação de incerteza e critérios estatísticos

Incerteza dos parâmetros identificados pela PINN (Hipótese 1). A incerteza de cada parâmetro θ_j será avaliada segundo o Guia para a Expressão da Incerteza de Medição (GUM) [71] e seu Suplemento 1 [72], com as componentes:

Componente	Fonte	Avaliação
Tipo A, repetibilidade	Variação entre replicatas de coreflood nas mesmas condições	$u_A = s/\sqrt{n}$ a partir das estimativas de θ_j em cada replicata
Tipo A, estimação	Variabilidade do próprio estimador (inicialização e dados)	Conjunto de PINNs treinadas com sementes diferentes [73] e *bootstrap* dos resíduos [74]
Tipo B, instrumentos	Transdutores de pressão, bomba, cromatografia iônica, temperatura, dimensões e porosidade do plug	Certificados de calibração e especificações, com distribuições normal ou retangular
Tipo B, modelo	Escolha da lei constitutiva (aditiva, porosidade crítica, aprendida)	Dispersão entre as estimativas obtidas com leis alternativas

Os coeficientes de sensibilidade $c_i = \partial\theta_j/\partial x_i$ às grandezas de entrada são obtidos por diferenciação automática da própria PINN, e a incerteza padrão combinada é

$$u_c(\theta_j) = \sqrt{u_A^2 + \sum_i c_i^2\, u_{B,i}^2 + u_{\text{mod}}^2 + 2\sum_{i<k} c_i c_k\, u(x_i, x_k)}, \tag{5}$$

com graus de liberdade efetivos pela fórmula de Welch-Satterthwaite e incerteza expandida $U = k\,u_c$, com k da distribuição t para 95% de abrangência. Como o modelo é não linear, o resultado linearizado será confrontado com a propagação por Monte Carlo do Suplemento 1: as grandezas de entrada são sorteadas de suas distribuições, a identificação é repetida (sobre o substituto, para viabilizar 10^4 a 10^5 amostras) e obtém-se a distribuição de θ_j, seu intervalo de abrangência de 95% e a matriz de covariância entre parâmetros, que evidencia correlações como a entre os coeficientes de filtração e de dano. Parâmetros estritamente positivos serão testados quanto à aderência a distribuições normal e log-normal (Shapiro-Wilk e Anderson-Darling), e a formulação bayesiana da PINN [75] será usada como verificação independente da distribuição *a posteriori*. A identificabilidade é verificada por perfis de verossimilhança [76].

Demonstração estatística da Hipótese 1. Três testes, em sequência:

(i) *Recuperação em dados sintéticos:* cerca de 200 conjuntos gerados pelo simulador com θ conhecido e ruído compatível com as incertezas tipo A e tipo B; o método deve ser não enviesado (teste t sobre o erro) e seus intervalos de 95% devem conter o valor verdadeiro em proporção compatível com 95% (teste binomial).

(ii) *Concordância com a calibração clássica:* as estimativas da PINN e do ajuste por mínimos quadrados sobre o simulador de volumes finitos devem ser compatíveis dentro das incertezas expandidas.

(iii) *Previsão cega:* para cada ensaio de teste, o erro normalizado $E_n = |y_{\mathrm{prev}} - y_{\mathrm{med}}| \big/ \sqrt{U_{\mathrm{prev}}^2 + U_{\mathrm{med}}^2}$ deve satisfazer $E_n \leq 1$ [77], e a calibração das incertezas previstas é verificada pela cobertura empírica dos intervalos e pelo histograma da transformada integral de probabilidade.

Comparação entre algoritmos de RL e teste da Hipótese 2. O desempenho de algoritmos de RL varia muito entre sementes aleatórias [78]. Cada algoritmo será treinado com pelo menos 10 sementes e avaliado em um conjunto de cenários de teste não usados no treino, com θ sorteado por Monte Carlo de $p(\theta \mid \mathcal{D})$. A incerteza paramétrica é propagada à decisão: para cada política, obtém-se a distribuição de $\alpha(T)$ e do custo, reportando mediana, quantis P10 e P90 e o valor em risco condicional (CVaR) dos 10% piores cenários. A agregação segue as recomendações de Agarwal et al. [79]: média interquartil (IQM) do retorno normalizado, intervalos de confiança de 95% por *bootstrap* estratificado sobre sementes e cenários, perfis de desempenho e probabilidade de melhoria entre pares de algoritmos. Comparações pareadas (mesmos cenários) usam o teste de postos sinalizados de Wilcoxon com correção de Holm para múltiplas comparações. O algoritmo escolhido é o de maior IQM cujo intervalo de confiança não se sobreponha ao dos demais, ou, havendo sobreposição, o de menor taxa de violação de restrições e menor CVaR. A Hipótese 2 é considerada confirmada se a probabilidade de melhoria da política sobre a reotimização míope tiver intervalo de 95% acima de 0,5 e o ganho mediano superar 5%.

6.8 Etapa 6 – Estimação em operação e validação com dados de campo

A mesma formulação inversa da etapa 3 é aplicada a dados de poço para estimar a evolução do dano e ajustar os parâmetros de cada poço. A separação entre dano e pressurização usa os dados de pressão de fundo e vazão, com análise do gráfico de Hall e de períodos de fechamento. O estimador é testado com os dados diários públicos do campo de Volve (Equinor), que incluem pressão de fundo, pressão de cabeça e volumes injetados, e as séries de injeção da ANP são usadas para testar a generalização do substituto a históricos de longo prazo. A incerteza do estimador permite ainda avaliar o valor da informação, isto é, quando vale a pena coletar uma nova medição antes de mudar a água.

6.9 Etapa 7 – Validação experimental da política e software

O teste final é experimental e verifica se as decisões tomadas no ambiente de simulação se sustentam no meio poroso real. Como o horizonte de vida do poço não cabe em um ensaio, a política é avaliada em escala de laboratório: o ambiente de simulação é reconfigurado com a geometria linear, as dimensões dos plugs e a faixa de vazões do coreflood, calibrado com os dados da primeira campanha, e o agente é ajustado nesse ambiente. Na segunda campanha no LRAP+, plugs da mesma rocha recebem, com o mesmo volume injetado e em réplicas, três sequências de águas e vazões: (i) a recomendada pela política de RL; (ii) a da reotimização periódica míope; e (iii) a do critério empírico de limites independentes por parâmetro. As sequências e as previsões do ambiente são definidas e registradas antes dos ensaios, para que a comparação seja cega em relação aos resultados. Medem-se $\alpha(t)$, os perfis de pressão, a composição do efluente e o depósito por microtomografia.

Dois resultados são extraídos. O primeiro é a ordenação medida das três sequências, que testa experimentalmente a Hipótese 2 nas condições ensaiadas. O segundo é o erro entre a injetividade prevista pelo ambiente de simulação e a medida (teste da Hipótese 3), avaliado com as incertezas expandidas da medição e da previsão pelo erro normalizado E_n (Seção 6.7).

O resultado tecnológico é um pacote de software aberto que integra o simulador físico, o modelo substituto, a PINN inversa, o ambiente de treinamento no padrão Gymnasium, os agentes treinados e o protocolo estatístico de avaliação, com uma interface de apoio à decisão que recebe os dados de água, rocha e operação de um poço e devolve a composição, o tratamento e a vazão recomendados, com a incerteza associada. A arquitetura separará o módulo de avaliação do dano e da injetividade do módulo de decisão e especificará uma interface externa de troca de dados. Essa interface documentará entradas de composição química, condições de injeção e estado do reservatório, bem como saídas esperadas de desempenho de recuperação e restrições operacionais. Em eventual aplicação industrial,

um modelo externo capaz de responder a alterações na composição da água poderá ser conectado à otimização para formular objetivos múltiplos ou restrições de recuperação. A especificação dessa interface será entregue no software; o acoplamento efetivo com simuladores proprietários, a otimização de EOR e sua validação não integram as metas deste projeto. O desenvolvimento segue práticas de engenharia de software (controle de versão, testes automatizados, integração contínua e documentação), para que o ambiente possa ser reutilizado por outros grupos e pela indústria.

7. Metas, entregas verificáveis e indicadores de acompanhamento

7.1 Metas e entregas verificáveis

#	Meta / entrega	Indicador	Mês
M1	Base de dados integrada (águas, rocha, operação, injetividade)	≥ 300 registros com metadados completos; documentação pública	9
M2	Simulador radial multiespécie	Balanço de massa fechado em $\geq 99\%$; reprodução de casos da literatura	15
M3	Análise de sensibilidade global	Índices de Sobol para todos os parâmetros não medidos; conjunto mínimo de caracterização definido	18
M4	Parâmetros identificados por PINN inversa (teste da Hipótese 1)	1 campanha de coreflood com replicatas (calibração e teste cego); erro na previsão cega de $\alpha \leq 15\%$; fechamento do balanço iônico $\geq 90\%$	24
M5	Modelo substituto validado	$R^2 \geq 0{,}95$ em teste cego; avaliação $\geq 10^3\times$ mais rápida que o simulador	26
M6	Agente de RL robusto e comparado com as três referências (teste da Hipótese 2)	Ganho sobre a reotimização míope $\geq 5\%$ em ≥ 50 cenários de teste; correlação de Spearman da ordenação $\geq 0{,}8$	34
M7	Estimador do dano em operação	Separação entre dano e pressurização em dados de Volve; erro de previsão em janela futura $\leq 10\%$	38
M8	Validação da política em coreflood (teste da Hipótese 3)	Sequência do agente com α final superior às de referência, em réplicas; erro do ambiente de simulação $\leq 15\%$	44
M9	Ferramenta de apoio à decisão (código aberto)	Repositório versionado (código, dados e modelos)	46
M10	Produção científica (Seção 9)	3 artigos submetidos a periódicos A1/A2 (P1–P3); 2 trabalhos completos apresentados no Rio Oil & Gas (C1) e em evento da SPE (C2)	20–46

7.2 Indicadores de acompanhamento

O acompanhamento acompanha os quatro relatórios parciais que condicionam a liberação das parcelas (item 8.4). Em cada relatório são verificadas as metas previstas para o período e indicadores de processo que mostram o avanço das atividades em curso, mesmo antes de a meta correspondente ser concluída.

Relatório	Metas a comprovar	Indicadores de processo
R1 (mês 12)	M1	Revisão sistemática concluída; simulador radial com módulo de incrustação implementado e balanço de massa verificado; plano experimental da campanha 1 definido pela análise de identificabilidade e ensaios iniciados; doutorando matriculado e iniciação científica selecionada; credenciamento no PEM; 2 ações em escolas
R2 (mês 24)	M2, M3, M4	Número de corefloods da campanha 1 realizados com réplicas e dados depositados no Zenodo; erro da previsão cega da Hipótese 1; primeira versão do modelo substituto; trabalho C1 apresentado; disciplina eletiva ofertada; ações de divulgação acumuladas
R3 (mês 36)	M5, M6	Número de algoritmos triados e aprofundados; resultado estatístico da Hipótese 2 (IQM, probabilidade de melhoria); P1 e P2 submetidos; estimador aplicado aos dados de Volve; sequências e previsões da campanha 2 registradas antes dos ensaios; exame de qualificação do doutorando; primeira proposta a edital externo submetida

Relatório	Metas a comprovar	Indicadores de processo
RF (mês 48)	M7, M8, M9, M10	Resultado da campanha 2 (teste da Hipótese 3); C2 apresentado e P3 submetido; software público com identificador permanente; tese em fase final; indicadores consolidados de divulgação (escolas, participantes, vídeos, acessos ao simulador)

Em todos os relatórios são informados também a execução orçamentária por elemento de despesa e o percentual de atividades do cronograma cumpridas no prazo.

8. Cronograma físico em meses corridos

O cronograma é contado a partir do início da execução; os relatórios parciais condicionam o desembolso de parcelas, conforme item 8.4. O detalhamento mensal será espelhado no plano de trabalho do SisFAPERJ. A Figura 2 apresenta as atividades mês a mês, com as metas (M), as publicações (C, P) e os relatórios parciais que condicionam as parcelas (R).

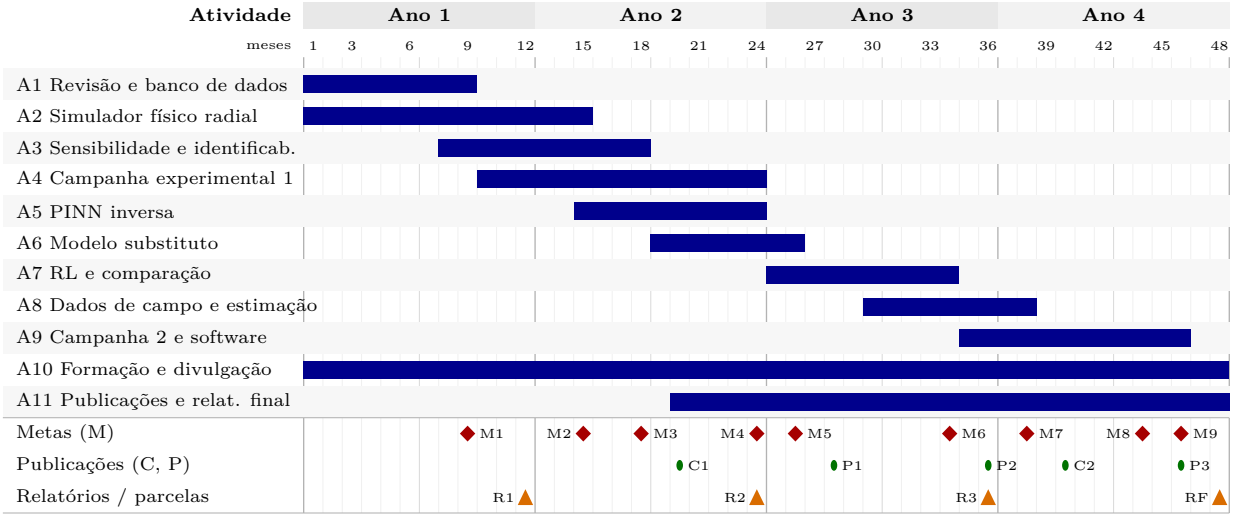


Figura 2: Cronograma físico mês a mês (48 meses de execução).

Atividade	Entrega / marco de acompanhamento	Meses
A1 Revisão sistemática e banco de dados	Base documentada, revisão e dados rastreáveis	1–9
A2 Simulador físico radial	Verificação, balanços e comparação bibliográfica	1–15
A3 Sensibilidade e identificabilidade	Morris, Sobol, plano experimental	8–18
A4 Campanha experimental 1	Calibração e teste cego de parâmetros	10–24
A5 PINN inversa	Estimação e incertezas	15–24
A6 Modelo substituto	Avaliação fora da amostra	19–26
A7 RL e comparação de estratégias	Comparação controlada e avaliação de segurança	25–34
A8 Dados de campo e estimação	Estudo de caso e análise de limitações	30–38
A9 Campanha 2 e software	Validação experimental e código público	35–46
A10 Formação e divulgação	Atividades educativas e relatórios	1–48
A11 Publicações e relatório final	Submissões em 20, 28, 36, 40 e 46; relatório final em 48	20–48

9. Resultados esperados

9.1 Resultados científicos

- Um simulador radial multiespécie do dano à formação que acopla incrustação, finos e argilas, filtração e dano biológico, e separa o dano da queda aparente de injetividade por pressurização do reservatório.
- Valores identificados, com incerteza, dos parâmetros que hoje entram como suposição nos modelos de injetividade (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas), para as rochas e águas estudadas, e uma metodologia de identificação por PINN inversa validada em ensaios cegos (Hipótese 1).
- Uma hierarquia, obtida por análise de sensibilidade global, dos fatores de água, rocha e operação que mais afetam a injetividade e a decisão sobre a água, com um conjunto mínimo de caracterização por rocha.
- Evidência quantitativa sobre o valor da decisão sequencial na escolha da água de injeção (Hipótese 2): se, e em que condições, uma política que antecipa a evolução do dano supera a reotimização periódica e os critérios empíricos. Um resultado negativo também é informativo, pois indicaria que métodos estáticos mais simples são suficientes.

- Evidência experimental, em coreflood, de que as decisões obtidas no ambiente de simulação se sustentam no meio poroso real (Hipótese 3).

9.2 Resultados tecnológicos

- Uma ferramenta de apoio à decisão, em código aberto, que recomenda composição, tratamento e vazão de injeção para um poço a partir de seus dados de água, rocha e operação, com a incerteza associada, e com interface documentada para a integração futura de modelos externos de recuperação.
- Um protocolo de ensaios de coreflood para caracterização da sensibilidade de rochas à água de injeção, reutilizável em outros campos.
- Um pacote de software aberto que integra simulador, modelo substituto, PINN inversa, ambiente de treinamento e agentes, com protocolo de avaliação reprodutível e especificação de interface modular para modelos externos de recuperação de petróleo.
- Curvas de decisão aplicáveis à operação, como o teor máximo de sulfato residual admissível em função do Ba^{2+} da água de formação e da vazão, e a avaliação técnica do tratamento por membranas de ePTFE/PTFE como alternativa à nanofiltração em campos com alto teor de bário.

9.3 Formação e consolidação institucional

- Uma tese de doutorado no PEM/COPPE e orientações de iniciação científica na interface entre engenharia de petróleo, química de águas e inteligência artificial.
- Uma linha de pesquisa nova no programa, com base de dados, códigos e protocolos experimentais que permanecem disponíveis após o término do apoio.

9.4 Produção científica

Três artigos em periódicos A1 ou A2 e dois trabalhos completos em congressos, um no Rio Oil & Gas e um em evento da SPE. Cada publicação corresponde a uma etapa e a uma hipótese, de modo que a produção acompanha o avanço do projeto e a tese de doutorado se organiza como coletânea desses artigos.

Tipo	Tema e contribuição	Veículo pretendido	Mês
C1 Congresso	Simulador radial multiespécie, sensibilidade global e curvas de decisão do sulfato residual admissível para campos da Bacia de Campos (etapas 1–2)	Rio Oil & Gas Expo and Conference (IBP)	20
P1 Periódico A1/A2	Identificação por PINN inversa dos parâmetros não medidos do dano, com corefloods do LRAP+, análise de identificabilidade e incerteza segundo o GUM (Hipótese 1; etapas 3–4)	SPE Journal; Water Resources Research; Journal of Computational Physics	28
P2 Periódico A1/A2	Escolha da água de injeção como decisão sequencial sob incerteza: comparação estatística das famílias de RL com reotimização míope e critérios empíricos (Hipótese 2; etapa 5)	Engineering Applications of Artificial Intelligence; Applied Energy; Geoenergy Science and Engineering	36
C2 Congresso	Separação entre dano e pressurização em dados de campo (Volve) e avaliação da política em histórico real de injeção (etapa 6)	SPE International Conference on Formation Damage Control ou SPE ATCE	40
P3 Periódico A1/A2	Validação experimental em coreflood de políticas de RL para a água de injeção: sequência do agente contra estratégias de referência e erro do ambiente de simulação (Hipótese 3; etapa 7)	SPE Journal; Geoenergy Science and Engineering; Fuel	46

Os meses indicam a submissão. A classificação A1/A2 de cada periódico será conferida na avaliação Qualis vigente no momento da submissão. Os resultados com potencial de proteção passam pela Agência UFRJ de Inovação antes da divulgação (Seção 20).

10. Riscos técnico-científicos e estratégias de mitigação

Risco	Mitigação	Nível
Poucos dados de injetividade com composição medida	Dados sintéticos calibrados em ensaios próprios; Volve	Alto
Parâmetros do dano não identificáveis com os dados disponíveis	Análise de identificabilidade antes dos ensaios; tomadas de pressão intermediárias, efluente e micro-CT; incerteza propagada ao agente	Médio
Dificuldade de treino da PINN em frentes abruptas	Ponderação adaptativa, treino progressivo no tempo; comparação com calibração clássica sobre o simulador	Médio
Modelos biológicos pouco validados	Tratar como módulo opcional; ensaios dedicados	Médio
Custo computacional do treinamento de RL	Modelo substituto; GPU dedicada	Médio
Política de RL fora do domínio físico válido	RL com restrições e filtro de segurança; verificação no simulador completo	Médio
Diferença entre o ambiente de simulação e o meio poroso real	Calibração na campanha 1, ajuste do agente ao ambiente em escala de laboratório e réplicas na campanha 2	Médio

Risco	Mitigação	Nível
Acesso a testemunhos e águas reais	Plugs de afloramento análogos e salmouras sintéticas de composição controlada; caracterização no LRAP+	Médio

11. Formação de recursos humanos

- Uma bolsa CAPES de doutorado (48 meses). A tese se divide naturalmente em duas partes: na primeira metade, desenho dos ensaios e identificação de parâmetros por PINN inversa (etapa 3); na segunda, modelo substituto e agente de RL (etapas 4 e 5). O credenciamento do proponente como orientador no PPG dependerá dos procedimentos e da aprovação institucional, devendo ocorrer antes da indicação do bolsista (item 8.12.1.1), prevista para os 3 primeiros meses de vigência. Perfil desejado: graduação e mestrado em Engenharia Mecânica, com conhecimento de programação em Python; experiência em ensaios laboratoriais com água de produção será considerada um diferencial.
- Duas iniciações científicas (FAPERJ e PIBIC/UFRJ) e projetos de fim de curso em Engenharia Mecânica e de Petróleo: ensaios (etapa 3), desenvolvimento do software (etapa 7) e simulador de divulgação.
- Disciplina eletiva no PEM (45 h, a partir do segundo ano) sobre aprendizado de máquina informado por física e RL em sistemas de energia, e minicurso de 8 h sobre IA aplicada à injeção de água.

12. Infraestrutura existente e necessária

12.1 Infraestrutura existente

Os ensaios de validação estão previstos no LRAP+ (COPPE/UFRJ), sujeitos à anuência formal do responsável e à confirmação da disponibilidade, das condições de acesso e da infraestrutura abaixo, indicada como potencialmente utilizável:

- sistema de coreflood HPHT para injeção de salmouras em plugs de rocha, com monitoramento de vazão e diferencial de pressão;
- poropermeâmetro Weatherford DV-4000 para porosidade e permeabilidade absoluta;
- microtomografia de raios X TESCAN CoreTom para caracterização do espaço poroso antes e depois dos ensaios;
- cromatografia de íons e cromatografia gasosa para análise dos efluentes;
- infraestrutura para preparação e caracterização de salmouras e fluidos.

12.2 Infraestrutura necessária

Estação de trabalho com GPU dedicada ao treinamento dos modelos substitutos e dos agentes de RL, que demandam milhares de episódios de simulação, e duas campanhas de ensaios no LRAP+ (Seção 19).

13. Redes e colaborações nacionais e internacionais

- LRAP+ (COPPE/UFRJ): ensaios de coreflood, caracterização petrofísica e análise química de efluentes.
- Programa de Engenharia Mecânica (COPPE/UFRJ): interação com os grupos de mecânica computacional e de fenômenos de transporte em meios porosos.
- Dados abertos de campo: conjunto Volve, disponibilizado pela Equinor, e dados públicos da ANP, usados na etapa 6.
- A estabelecer no primeiro ano: grupos internacionais de referência em dano à formação [11, 30], para validação cruzada do simulador, e operadoras das Bacias de Campos e de Santos, via cláusula de P,D&I da ANP, para dados de poços injetores e aplicação da ferramenta.

14. Impacto esperado e público beneficiado

14.1 Impacto científico, tecnológico, social, econômico e ambiental

- **Científico:** uma formulação nova para a escolha da água de injeção, como decisão sequencial sob incerteza com o dano à formação como dinâmica do sistema; valores identificados, com incerteza metrológica, de parâmetros que a literatura trata como ajuste empírico; e uma comparação estatisticamente controlada de famílias de RL em um problema de engenharia de reservatórios, com protocolo reprodutível.
- **Tecnológico e econômico:** menor frequência de intervenções corretivas (acidificação, *scale squeeze*, *workover*), menor consumo elétrico de bombeamento pela menor sobrepressão de injeção, especificação de tratamento ajustada a cada poço em vez de superdimensionada, e manutenção da reposição de volume que sustenta a recuperação de óleo. A modularidade permite eventual integração, por operadoras, de modelos de recuperação para avaliar compromissos entre injetividade e produção, sem que o projeto reivindique ganhos de recuperação não demonstrados.
- **Ambiental:** maior reaproveitamento da água produzida por reinjeção, menor descarte no mar, dosagem de inibidores e biocidas ajustada à necessidade real, e menor consumo de energia por metro cúbico injetado.
- **Social:** formação de pessoas qualificadas no Estado do Rio de Janeiro na interface entre engenharia de petróleo, química de águas e inteligência artificial, com um doutorado, iniciações científicas e projetos de fim de curso, e a oferta de disciplina e minicurso abertos a estudantes da UFRJ; essa qualificação amplia a empregabilidade

dos egressos na cadeia de óleo e gás fluminense e em setores que demandam IA aplicada. As ações em escolas da rede pública e os materiais de divulgação (Seção 17) aproximam estudantes do ensino médio da ciência e da engenharia ligadas à principal atividade econômica do Estado.

14.2 Público beneficiado e impacto institucional

- **Público beneficiado:** operadoras de campos offshore e empresas de serviços de tratamento de água e estimulação; a ANP e órgãos ambientais, por meio de critérios técnicos para reinjeção; grupos de pesquisa em engenharia de petróleo e em IA aplicada; e estudantes de graduação e pós-graduação da UFRJ.
- **Institucional:** uma linha de pesquisa nova no PEM/COPPE, com base de dados, protocolos experimentais e códigos que permanecem disponíveis após o apoio.

15. Contribuição para o desenvolvimento do Estado do Rio de Janeiro

O Rio de Janeiro é um polo central da produção nacional de petróleo, nas Bacias de Campos e de Santos, e boa parte dela vem de campos maduros sob injeção de água ou de campos do pré-sal em que a reinjeção de água produzida cresce com o corte de água. A incrustação por $BaSO_4$ é o problema dominante nos históricos operacionais da Bacia de Campos [7, 15], e prolongar a vida útil desses campos tem efeito direto sobre os royalties e participações especiais que sustentam parte relevante das receitas do Estado e dos municípios produtores. O projeto contribui ao produzir conhecimento e ferramentas aplicáveis a esses campos, ao formar no Estado pessoal qualificado na interface entre engenharia de petróleo e inteligência artificial, demandado pela cadeia de óleo e gás fluminense, e ao fortalecer a capacidade de pesquisa da COPPE/UFRJ em um tema com potencial de cooperação com as empresas sediadas no Rio de Janeiro. O tratamento de água produzida para reinjeção também se alinha às metas de redução de descarte de efluentes no mar.

16. Estratégia de integração e fixação institucional

16.1 Inserção na instituição executora

O proponente já atua no Programa de Engenharia Mecânica da COPPE/UFRJ como pesquisador de pós-doutorado há mais de dois anos, o que assegura a inserção imediata no programa, o conhecimento de seus grupos e laboratórios e a continuidade das colaborações iniciadas nesse período. Com o apoio do PROFIX-RJ, o proponente atuará no Programa de Engenharia Mecânica da COPPE/UFRJ, com os ensaios experimentais conduzidos na infraestrutura do LRAP+ (Seção 12), e com a estação de trabalho adquirida pelo projeto incorporada ao patrimônio da UFRJ.

16.2 Linha de pesquisa a ser criada

Inteligência artificial informada por física para injeção de água e dano à formação, reunindo modelagem do dano, identificação de parâmetros, aprendizado por reforço e validação experimental em meios porosos.

16.3 Infraestrutura disponibilizada

A COPPE/UFRJ disponibilizará ao proponente posto de trabalho no Programa de Engenharia Mecânica, com acesso à rede institucional e às instalações básicas (energia elétrica e água), condições que já lhe são oferecidas como pós-doutorando, além do acesso às bibliotecas da UFRJ e ao Portal de Periódicos CAPES. Os ensaios experimentais serão realizados no LRAP+ (Seção 12). A capacidade computacional necessária ao treinamento dos modelos não é suprida pela infraestrutura atual e é solicitada neste projeto (Seção 19); a estação de trabalho será incorporada ao patrimônio da UFRJ e permanecerá disponível ao grupo após o término do apoio.

16.4 Integração ao Programa de Pós-Graduação

Credenciamento como orientador no PEM antes da indicação do bolsista CAPES de doutorado; oferta de uma disciplina eletiva sobre aprendizado de máquina informado por física e aprendizado por reforço aplicados a sistemas de energia; coorientação de dissertações e de iniciação científica.

16.5 Plano de sustentabilidade após o término do apoio

A base de dados, o simulador, o protocolo de ensaios e o software formam uma plataforma que viabiliza propostas a editais da FAPERJ (Jovem Cientista do Nosso Estado, Apoio a Grupos Emergentes), ao CNPq (Universal, Produtividade em Pesquisa) e projetos com a indústria financiados pela cláusula de investimento em P,D&I da ANP. A primeira proposta externa será submetida até o terceiro ano do projeto.

17. Plano de educação, comunicação, popularização e divulgação científica

O plano traduz uma pergunta concreta, *por que a água que entra em um poço de petróleo precisa ser escolhida com cuidado?*, para públicos não especializados, e acompanha o cronograma (atividade A10):

Ação (item 2.20)	Descrição	Público e meta
Ações em escolas (I)	Oficina com experimento simples de incompatibilidade de águas (precipitação de sulfato de bário ou de cálcio em sala) e sua ligação com a indústria do Estado	Ensino médio da rede pública; 2 escolas por ano
Espaços de ciência e eventos (II, VI)	Participação na Semana Nacional de Ciência e Tecnologia e em atividades abertas da UFRJ, com o infográfico do projeto e o simulador interativo	Público geral
Materiais audiovisuais (III)	Vídeos curtos sobre água produzida, incrustação e IA na indústria	Redes sociais; 6 vídeos
Atividades digitais (IV, VII)	Simulador interativo na web, em que o visitante escolhe a água e vê a injetividade cair ou se manter	Estudantes e professores
Comunicação pública (V)	Textos de divulgação e entrevistas sobre os resultados, em linguagem acessível	Imprensa e público geral

O bolsista de doutorado e os alunos de iniciação científica participam das ações, como parte da formação. O alcance é acompanhado por indicadores simples (número de escolas, participantes, visualizações e acessos ao simulador) e relatado nos relatórios parciais.

18. Estratégia de acesso, preservação e difusão dos resultados

Os artigos serão publicados preferencialmente em periódicos de acesso aberto ou depositados como versão aceita em repositório (arXiv e repositório institucional da UFRJ). Códigos, modelos treinados e dados gerados pelo projeto serão publicados em repositório público versionado (GitHub) com identificador permanente (Zenodo), licença aberta e documentação que permita reproduzir os resultados, respeitadas as restrições de dados de terceiros e de eventual proteção intelectual. A ferramenta de apoio à decisão e o simulador de divulgação serão disponibilizados gratuitamente.

19. Orçamento detalhado e justificado

Os valores apresentados são estimativas orçamentárias e não constituem comprovação de preço. A submissão exige anexar as propostas e conservar três cotações por item (ou justificativa formal para menos fornecedores), conforme item 9.6.1. Não estão previstos remanejamentos entre capital e custeio (item 9.8). A elegibilidade dos serviços de laboratório na própria instituição executora deverá ser confirmada pela FAPERJ antes da contratação.

Grupo	Item e justificativa	Qtd.	Valor (R$)
Capital – estação de trabalho para treinamento (etapas 3 a 5; OE3, OE4)			
	GPU NVIDIA RTX PRO 6000 Blackwell 96 GB (estimativa): treinamento de operadores neurais, PINNs e RL; aquisição condicionada à comparação documentada com GPU de 48 GB e infraestrutura institucional disponível	1	113.100,00
	Processador de 16 núcleos (AMD Ryzen 9 9950X ou equivalente)	1	4.200,00
	Placa-mãe com PCIe 5.0 x16 (chipset X870E ou equivalente)	1	3.600,00
	Memória 128 GB DDR5 (2 × 64 GB)	1	8.000,00
	SSD NVMe 4 TB PCIe 4.0	1	3.400,00
	Fonte 1600 W, 80 Plus Platinum, ATX 3.1 (GPU de 600 W)	1	3.500,00
	Gabinete e refrigeração do processador	1	2.200,00
	Monitor 27 polegadas 4K	1	2.600,00
	Nobreak senoidal 3 kVA	1	4.200,00
	Subtotal capital		144.800,00
Custeio – serviços de terceiros, pessoa jurídica (etapas 3 e 7; OE4, OE8)			
	Serviço experimental de pessoa jurídica, sujeito à comprovação da possibilidade de contratação e orçamento: preparação e caracterização petrofísica dos plugs, corefloods com replicatas, cromatografia de íons do efluente, microtomografia antes e depois e mineralogia (DRX e MEV). Campanha 1: calibração e teste cego da Hipótese 1 (etapa 3); campanha 2: validação da política (Hipótese 3, etapa 7)	2	50.000,00
Custeio – material de consumo			
	Teclado e mouse da estação de trabalho	1	500,00
	Sais e reagentes para preparo de salmouras e para a oficina em escolas (ação de popularização)	–	4.700,00
	Subtotal custeio		55.200,00
	Total		**200.000,00**

20. Ética, integridade, biossegurança, propriedade intelectual e dados de pesquisa

- **Ética e integridade:** o projeto não envolve seres humanos, animais nem acesso ao patrimônio genético. Os ensaios seguem as normas de segurança do LRAP+ para fluidos pressurizados e o descarte de salmouras e reagentes segue os procedimentos da UFRJ.

- **Dados de terceiros:** usados conforme suas licenças (Volve: CC BY-NC-SA 4.0, uso não comercial; dados da ANP: dados abertos), com citação da fonte.
- **Plano de gestão de dados:** dados brutos de ensaios, metadados de cada ensaio (amostra, fluidos, condições, instrumentos e certificados de calibração), códigos e modelos versionados; cópia de segurança institucional; publicação no Zenodo ao fim de cada etapa, com conjunto de dados descrito segundo os princípios FAIR.
- **Propriedade intelectual:** o software da ferramenta de apoio à decisão pode ser objeto de registro de programa de computador no INPI. Antes de qualquer divulgação, os resultados com potencial de proteção serão avaliados com a Agência UFRJ de Inovação, conforme a Lei nº 9.279/1996 e o Marco Legal de CT&I (item 12.20).

Referências

[1] F. Macedonio, A. Ali, T. Poerio, E. El-Sayed, E. Drioli, and M. Abdel-Jawad. Direct contact membrane distillation for treatment of oilfield produced water. *Separation and Purification Technology*, 126:69–81, 2014.

[2] T. El-badawy, M. H. D. Othman, T. Matsuura, M. R. Bilad, M. R. Adam, Z. S. Tai, J. Ravi, A. F. Ismail, M. A. Rahman, J. Jaafar, J. Usman, and T. A. Kurniawan. Progress in treatment of oilfield produced water using membrane distillation and potentials for beneficial re-use. *Separation and Purification Technology*, 278:119494, 2021.

[3] Y. Liang, Y. Ning, L. Liao, and B. Yuan. Special focus on produced water in oil and gas fields: Origin, management, and reinjection practice. In *Formation Damage During Improved Oil Recovery: Fundamentals and Applications*, pages 515–586. Gulf Professional Publishing, 2018.

[4] M. S. Kamal, I. Hussein, M. Mahmoud, A. S. Sultan, and M. A. S. Saad. Oilfield scale formation and chemical removal: A review. *Journal of Petroleum Science and Engineering*, 171:127–139, 2018.

[5] A. B. Bin Merdhah, A. A. M. Yassin, and M. A. Muherei. Laboratory and prediction of barium sulfate scaling at high-barium formation water. *Journal of Petroleum Science and Engineering*, 70(1–2):79–88, 2010.

[6] P. G. Bedrikovetsky, E. J. Mackay, R. M. P. Silva, F. M. R. Patricio, and F. F. Rosário. Produced water re-injection with seawater treated by sulphate reduction plant: Injectivity decline, analytical model. *Journal of Petroleum Science and Engineering*, 68(1–2):19–28, 2009.

[7] A. A. Rocha, M. Frydman, S. A. B. da Fontoura, F. F. Rosário, and M. C. M. Bezerra. Numerical modeling of salt precipitation during produced water reinjection. In *SPE International Symposium on Oilfield Scale*, Aberdeen, United Kingdom, 2001. SPE-68336-MS.

[8] R. Miri and H. Hellevang. Salt precipitation during CO_2 storage – a review. *International Journal of Greenhouse Gas Control*, 51:136–147, 2016.

[9] M. Kamalipour, S. A. Mousavi Dehghani, A. Naseri, and S. Abbasi. Role of agitation and temperature on calcium sulfate crystallization in water injection process. *Journal of Petroleum Science and Engineering*, 151:362–372, 2017.

[10] PENDENTE. Effects of salinity and rock clogging on injectivity dynamics of flooding wells: Experiments, modeling and validation on field data. *Journal of Petroleum Science and Engineering*, 2021. PENDENTE: completar autores, volume e páginas.

[11] S. Pang and M. M. Sharma. A model for predicting injectivity decline in water-injection wells. *SPE Formation Evaluation*, 12(3):194–201, 1997.

[12] O. R. Pal and N. S. Al-Ghamdi. Integrated analysis approach of water and solids for root cause of injectivity decline of water injection well – a case study. *Geoenergy Science and Engineering*, 231:212351, 2023.

[13] H. M. Kermani, M. Bonto, and H. M. Nick. Chemical solutions for restoring scaling-induced injectivity impairment in offshore produced water re-injection. *Science of the Total Environment*, 903:166597, 2023.

[14] A. Shabani, A. Kalantariasl, M. Parvazdavani, and S. Abbasi. Geochemical and hydrodynamic modeling of permeability impairment due to composite scale formation in porous media. *Journal of Petroleum Science and Engineering*, 176:1071–1081, 2019.

[15] M. C. M. Bezerra, F. F. Rosário, A. A. Rocha, and C. L. Sombra. Assessment of scaling tendency of Campos Basin fields based on the characterization of formation waters. In *SPE International Symposium on Oilfield Scale*, Aberdeen, United Kingdom, 2004. SPE-87452-MS.

[16] Aftab Hussain Arain, Ahmad Salam Farooqi, and Rayed S. Alshareef. Advancing low-salinity waterflooding for improved oil recovery: Mechanisms, machine learning, and future directions. *Petroleum Research*, 2026. Article in press; accepted 30 July 2026.

[17] Ali Shafiei, Afshin Tatar, Mahsheed Rayhani, Madiyar Kairat, and Ingkar Askarova. Artificial neural network, support vector machine, decision tree, random forest, and committee machine intelligent system help to improve performance prediction of low salinity water injection in carbonate oil reservoirs. *Journal of Petroleum Science and Engineering*, 219:111046, 2022.

[18] A. Tatar, I. Askarova, A. Shafiei, and M. Rayhani. Data-driven connectionist models for performance prediction of low salinity waterflooding in sandstone reservoirs. *ACS Omega*, 6:32304–32326, 2021.

[19] J. Kondori, M. I. Miah, S. Zendehboudi, F. Khan, and D. Heagle. Hybrid connectionist models to assess recovery performance of low salinity water injection. *Journal of Petroleum Science and Engineering*, 197:107833, 2021.

[20] Leonardo Fonseca Reginato, Rafael dos Santos Gioria, and Marcio Augusto Sampaio. Hybrid machine learning for modeling the relative permeability changes in carbonate reservoirs under engineered water injection. *Energies*, 16(13):4849, 2023.

[21] Diana Mercado Sierra, Argenis Alvarez Rojas, and Victor Salazar Araque. Low-salinity water-injection optimization in the namorado field using compositional simulation and artificial intelligence, 2020. SPE 198995; ver tambem resumo no Journal of Petroleum Technology, doi:10.2118/0920-0065-JPT.

[22] A new insight into pilot-scale development of low-salinity polymer flood using an intelligent-based proxy model coupled with particle swarm optimization. Scientific Reports, 2024.

[23] Shibao Yuan, Jia Song, Fengxiang Yang, Haiyan Jiang, and Zihan Ren. Research on the connectivity between injection and production wells in the hongqian in situ combustion project in xinjiang based on machine learning. *Engineering Applications of Artificial Intelligence*, 172:114337, 2026.

[24] Research on intelligent regulation of layered water injection based on reinforcement learning sac algorithm. Scientific Reports, 2025.

[25] Scalable and adaptive injection-production control in reservoirs via a multi-agent reinforcement learning approach, 2025.

[26] Spatiotemporal graph-based surrogate modeling and deep reinforcement learning for multi-layer injection-production decision in waterflood reservoirs, 2026.

[27] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.

[28] James R. Bulau and M. Matt Honarpour. A quality control program in core analysis. In *International Symposium of the Society of Core Analysts*, number SCA-9713, Calgary, Canada, 1997.

[29] J. D. Jansen, S. G. Douma, D. R. Brouwer, P. M. J. Van den Hof, O. H. Bosgra, and A. W. Heemink. Closed-loop reservoir management. In *SPE Reservoir Simulation Symposium*, number SPE-119098-MS, The Woodlands, Texas, USA, 2009.

[30] P. Bedrikovetsky, D. Marchesin, F. Shecaira, A. L. Souza, P. V. Milanez, and E. Rezende. Characterisation of deep bed filtration system from laboratory pressure drop measurements. *Journal of Petroleum Science and Engineering*, 32(2–4):167–177, 2001.

[31] G. H. Nancollas and S. T. Liu. Crystal growth and dissolution of barium sulfate. *SPE Journal*, 15(6):509–516, 1975.

[32] M. D. Morris. Factorial sampling plans for preliminary computational experiments. *Technometrics*, 33(2):161–174, 1991.

[33] I. M. Sobol'. Global sensitivity indices for nonlinear mathematical models and their Monte Carlo estimates. *Mathematics and Computers in Simulation*, 55(1–3):271–280, 2001.

[34] O. Fuks and H. A. Tchelepi. Limitations of physics informed machine learning for nonlinear two-phase transport in porous media. *Journal of Machine Learning for Modeling and Computing*, 1(1):19–37, 2020.

[35] L. Lu, P. Jin, G. Pang, Z. Zhang, and G. E. Karniadakis. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3:218–229, 2021.

[36] Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart, and A. Anandkumar. Fourier neural operator for parametric partial differential equations. In *International Conference on Learning Representations (ICLR)*, 2021.

[37] M. Lutter, S. Mannor, J. Peters, D. Fox, and A. Garg. Robust value iteration for continuous control tasks. In *Robotics: Science and Systems XVII*, 2021.

[38] PENDENTE. Monte Carlo-based reinforcement learning control for unmanned aerial vehicle systems. *Neurocomputing*, 2022. PENDENTE: completar autores e volume.

[39] S. A. A. Rizvi, A. Pertzborn, and Z. Lin. Reinforcement learning based optimal tracking control under unmeasurable disturbances with application to HVAC systems. *IEEE Transactions on Neural Networks and Learning Systems*, 2021.

[40] S. A. A. Rizvi and A. Pertzborn. Development of a bias compensating Q-learning controller for a multi-zone HVAC facility. *IEEE/CAA Journal of Automatica Sinica*, 10(8), 2023.

[41] X. Fang, G. Gong, G. Li, L. Chun, P. Peng, W. Li, X. Shi, and X. Chen. Deep reinforcement learning optimal control strategy for temperature setpoint real-time reset in multi-zone building HVAC system. *Applied Thermal Engineering*, 212:118552, 2022.

[42] K. Al Sayed, A. Boodi, R. Sadeghian Broujeny, and K. Beddiar. Multi-objective HVAC control using modified hybrid deep reinforcement learning algorithms. *Energy and AI*, 25:100850, 2026.

[43] PENDENTE. Develop a navigation approach for mobile robots based on the distributional deep reinforcement learning framework. In *10th International Conference on Computer and Communications (ICCC)*, 2024. PENDENTE: completar autores e páginas.

[44] J. Achiam, D. Held, A. Tamar, and P. Abbeel. Constrained policy optimization. In *International Conference on Machine Learning (ICML)*, pages 22–31, 2017.

[45] Y. Nakamura, T. Mori, Y. Tokita, T. Shibata, and S. Ishii. Off-policy natural policy gradient method for a biped walking using a CPG controller. *Journal of Robotics and Mechatronics*, 17(6):636–644, 2005.

[46] A. Centurelli, L. Arleo, A. Rizzo, S. Tolu, C. Laschi, and E. Falotico. Closed-loop dynamic control of a soft manipulator using deep reinforcement learning. *IEEE Robotics and Automation Letters*, 7(2):4741–4748, 2022.

[47] A. Ray, J. Achiam, and D. Amodei. Benchmarking safe exploration in deep reinforcement learning. Technical report, OpenAI, 2019.

[48] PENDENTE. Reinforcement learning based optimal control of multiple building HVAC systems and analysis of influencing factors. *Journal of Building Engineering*, 2025. PENDENTE: completar autores e volume.

[49] X. Zhong, Z. Zhang, R. Zhang, and C. Zhang. End-to-end deep reinforcement learning control for HVAC systems in office buildings. *Designs*, 6(3):52, 2022.

[50] Y. Du, H. Zandi, O. Kotevska, K. Kurte, J. Munk, K. Amasyali, E. Mckee, and F. Li. Intelligent multi-zone residential HVAC control strategy based on deep reinforcement learning. *Applied Energy*, 281:116117, 2021.

[51] Y. Fan, H. Dong, X. Zhao, and P. Denissenko. Path-following control of unmanned underwater vehicle based on an improved TD3 deep reinforcement learning. *IEEE Transactions on Control Systems Technology*, 32(5):1904–1919, 2024.

[52] Z. Ben Hazem. A fuzzy-TD3 hybrid reinforcement learning framework for robust trajectory tracking of the Mitsubishi RV-2AJ robotic arm. *Scientific Reports*, 16:12269, 2026.

[53] A. Silvestri, D. Coraci, S. Brandi, A. Capozzoli, E. Borkowski, J. Köhler, D. Wu, M. N. Zeilinger, and A. Schlueter. Real building implementation of a deep reinforcement learning controller to enhance energy efficiency and indoor temperature control. *Applied Energy*, 368:123447, 2024.

[54] X. Wang, N. Mahdavi, S. Sethuvenkatraman, and S. West. An environment-adaptive SAC-based HVAC control of single-zone residential and office buildings. *Data-Centric Engineering*, 6:e3, 2025.

[55] T. El-Agroudi, F. G. Maurer, J. A. Olsen, and K. Alexis. In-flight attitude control of a quadruped using deep reinforcement learning. In *Proceedings of The 8th Conference on Robot Learning*, volume 270 of *Proceedings of Machine Learning Research*, pages 5014–5029, 2025.

[56] B. Hu, J. Li, J. Yang, H. Bai, S. Li, Y. Sun, and X. Yang. Reinforcement learning approach to design practical adaptive control for a small-scale intelligent vehicle. *Symmetry*, 11(9):1139, 2019.

[57] PENDENTE. Experimental application of soft-constrained model-based reinforcement learning to a real underactuated robot. *IFAC-PapersOnLine*, 2025. PENDENTE: confirmar título, autores e páginas.

[58] M. Ye and A. H. Elsheikh. Model-based reinforcement learning for active flow control. *Physics of Fluids*, 37(9):093363, 2025.

[59] P. Wu, A. Escontrela, D. Hafner, P. Abbeel, and K. Goldberg. DayDreamer: World models for physical robot learning. In *Proceedings of The 6th Conference on Robot Learning*, volume 205 of *Proceedings of Machine Learning Research*, pages 2226–2240, 2023.

[60] D. J. B. Harrold, J. Cao, and Z. Fan. Renewable energy integration and microgrid energy trading using multi-agent deep reinforcement learning. *Applied Energy*, 318:119151, 2022.

[61] B. Yun, J. Shim, J. Moon, S. Lee, K. Jeong, and K. H. Cho. Towards autonomous operation of two-stage reverse osmosis water treatment system with multi-agent reinforcement learning. *Desalination*, 609:118870, 2025.

[62] PENDENTE. Multiagent deep reinforcement learning-based distributed control strategy for energy management in DC microgrid. *Computers and Electrical Engineering*, 2025. PENDENTE: confirmar título, autores e volume.

[63] D. Qiu, Y. Wang, T. Zhang, M. Sun, and G. Strbac. Hierarchical multi-agent reinforcement learning for repair crews dispatch control towards multi-energy microgrid resilience. *Applied Energy*, 336:120826, 2023.

[64] L. He, X. Qi, D. Chen, Z. Li, and X. Tan. DiSA-IQL: Offline reinforcement learning for robust soft robot control under distribution shifts, 2025. arXiv:2510.00358.

[65] A. Nair, A. Gupta, M. Dalal, and S. Levine. AWAC: Accelerating online reinforcement learning with offline datasets, 2020. arXiv:2006.09359.

[66] X. Yang, Z. Ji, J. Wu, Y.-K. Lai, C. Wei, G. Liu, and R. Setchi. Hierarchical reinforcement learning with universal policies for multistep robotic manipulation. *IEEE Transactions on Neural Networks and Learning Systems*, 33(9):4727–4741, 2022.

[67] PENDENTE. Hierarchical reinforcement learning with adaptive scheduling for robot control. *Engineering Applications of Artificial Intelligence*, 2023. PENDENTE: completar autores e volume.

[68] H. Wan, Y. Tian, C. Wang, X. Luan, H. R. Karimi, and F. Liu. Aperiodic speed tracking control of unmanned sightseeing vehicles based on hierarchical reinforcement learning. *International Journal of Systems Science*, 56(10):2343–2356, 2025.

[69] O. Nachum, S. Gu, H. Lee, and S. Levine. Data-efficient hierarchical reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.

[70] Y. Nasir and L. J. Durlofsky. Deep reinforcement learning for optimal well control in subsurface systems with uncertain geology, 2022. arXiv:2203.13375.

[71] JCGM. Evaluation of measurement data – guide to the expression of uncertainty in measurement (JCGM 100:2008). Technical report, Joint Committee for Guides in Metrology, 2008.

[72] JCGM. Evaluation of measurement data – supplement 1 to the GUM: Propagation of distributions using a Monte Carlo method (JCGM 101:2008). Technical report, Joint Committee for Guides in Metrology, 2008.

[73] B. Lakshminarayanan, A. Pritzel, and C. Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[74] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, New York, 1993.

[75] L. Yang, X. Meng, and G. E. Karniadakis. B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data. *Journal of Computational Physics*, 425:109913, 2021.

[76] A. Raue, C. Kreutz, T. Maiwald, J. Bachmann, M. Schilling, U. Klingmüller, and J. Timmer. Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood. *Bioinformatics*, 25(15):1923–1929, 2009.

[77] ISO. ISO 13528:2022 – statistical methods for use in proficiency testing by interlaboratory comparison, 2022. International Organization for Standardization, Genebra.

[78] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger. Deep reinforcement learning that matters. In *AAAI Conference on Artificial Intelligence*, pages 3207–3214, 2018.

[79] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.