UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO ALBERTO LUIZ COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA DE ENGENHARIA – COPPE
PROGRAMA DE ENGENHARIA MECÂNICA – PEM

Proposta submetida ao

Edital FAPERJ nº 34/2026 – Programa de Apoio à Fixação de Doutores no Estado do Rio de Janeiro – Conhecimento Brasil / PROFIX-RJ (FAPERJ/CNPq/CAPES)

Otimização da composição química da água de injeção baseada em dados geológicos, geoquímicos e operacionais por algoritmos de aprendizado por reforço e redes neurais informadas pela física (PINNs) para preservação da injetividade

Proponente: **Ramon de Paoli Mendes**

Instituição executora	Universidade Federal do Rio de Janeiro (UFRJ)
Programa de Pós-Graduação	Programa de Engenharia Mecânica (PEM) – COPPE/UFRJ
Grande área / área / subárea	Engenharias / Engenharia de Petróleo
Eixo estratégico	Óleo e gás
Bolsa CAPES pleiteada	Doutorado (48 meses)
Duração	48 meses (+3 meses para indicação dos bolsistas CAPES)
Auxílio FAPERJ solicitado	R$ 200.000,00

Rio de Janeiro
Novembro de 2026

Sumário

Resumo . . . 1
1 Justificativa e diagnóstico da situação atual . . . 1
2 Estado da arte . . . 2
3 Trajetória do proponente e aderência ao projeto . . . 4
4 Questão científica, tecnológica ou de inovação e hipóteses . . . 4
5 Objetivos . . . 5
5.1 Objetivo geral . . . 5
5.2 Objetivos específicos . . . 5
6 Metodologia . . . 5
6.1 Formulação: decisão sequencial sob observação parcial . . . 5
6.2 Etapa 1 – Modelo físico do dano . . . 6
6.3 Etapa 2 – Análise de sensibilidade global . . . 7
6.4 Etapa 3 – Ensaios no LRAP+ e identificação por PINN inversa . . . 7
6.5 Etapa 4 – Modelo substituto . . . 7
6.6 Etapa 5 – Agente de aprendizado por reforço . . . 7
6.7 Quantificação de incerteza e critérios estatísticos . . . 8
6.8 Etapa 6 – Estimação em operação e validação com dados de campo . . . 9
6.9 Etapa 7 – Validação experimental da política e software . . . 9
7 Metas, entregas verificáveis e indicadores de acompanhamento . . . 10
7.1 Metas e entregas verificáveis . . . 10
7.2 Indicadores de acompanhamento . . . 10
8 Cronograma físico em meses corridos . . . 11
9 Resultados esperados . . . 11
9.1 Resultados científicos . . . 11
9.2 Resultados tecnológicos . . . 12
9.3 Formação e consolidação institucional . . . 12
9.4 Produção científica . . . 12
10 Riscos técnico-científicos e estratégias de mitigação . . . 12
11 Formação de recursos humanos . . . 13
12 Infraestrutura existente e necessária . . . 13
12.1 Infraestrutura existente . . . 13
12.2 Infraestrutura necessária . . . 13
13 Redes e colaborações nacionais e internacionais . . . 13
14 Impacto esperado e público beneficiado . . . 13
14.1 Impacto científico, tecnológico, social, econômico e ambiental . . . 13
14.2 Público beneficiado e impacto institucional . . . 14
15 Contribuição para o desenvolvimento do Estado do Rio de Janeiro . . . 14
16 Estratégia de integração e fixação institucional . . . 14
16.1 Inserção na instituição executora . . . 14
16.2 Linha de pesquisa a ser criada . . . 14
16.3 Infraestrutura disponibilizada . . . 14
16.4 Integração ao Programa de Pós-Graduação . . . 14
16.5 Plano de sustentabilidade após o término do apoio . . . 14
17 Plano de educação, comunicação, popularização e divulgação científica . . . 15
18 Estratégia de acesso, preservação e difusão dos resultados . . . 15
19 Orçamento detalhado e justificado . . . 15
20 Ética, integridade, biossegurança, propriedade intelectual e dados de pesquisa . . . 16
Referências . . . 16

Resumo

A reinjeção de água produzida, isoladamente ou misturada à água do mar tratada, é uma estratégia para a gestão da água e a manutenção da pressão em reservatórios de petróleo. Entretanto, a composição físico-química da água injetada pode comprometer a injetividade por mecanismos de dano à formação que interagem e evoluem ao longo do tempo, incluindo precipitação de incrustações minerais ($BaSO_4$, $CaCO_3$ e $SrSO_4$), migração e inchamento de argilas, retenção de partículas e gotículas de óleo, formação de reboco e atividade microbiológica. A intensidade desses fenômenos depende da mineralogia, das propriedades petrofísicas e da estrutura porosa da rocha, da composição das águas de formação, produzida e do mar, bem como das condições operacionais do poço. Apesar dessas interdependências, a especificação da água de injeção frequentemente se apoia em análises de compatibilidade e critérios de tratamento avaliados separadamente, sem incorporar plenamente o caráter cumulativo do dano.

Este projeto tem como objetivo desenvolver e validar uma metodologia computacional híbrida capaz de determinar e atualizar, ao longo da operação, a composição físico-química da água de injeção que melhor preserva a injetividade, respeitando restrições técnicas, econômicas e de segurança. A metodologia será organizada em sete etapas interdependentes: (i) desenvolvimento de um simulador físico de transporte reativo e evolução do dano à formação, com representação dos mecanismos geoquímicos, de retenção e de alteração da permeabilidade; (ii) análise de sensibilidade global e de identificabilidade para selecionar parâmetros dominantes e orientar os ensaios; (iii) realização de ensaios de *coreflooding* para identificação inversa, por PINNs, dos parâmetros físico-químicos e constitutivos que governam o dano à formação, com calibração do simulador e quantificação das incertezas; (iv) treinamento e validação de modelos substitutos (surrogate model) que reproduzam a resposta dinâmica do simulador com menor custo computacional; (v) treinamento e comparação de algoritmos de aprendizado por reforço (RL) para definir sequencialmente as proporções de mistura entre fontes de água, a composição iônica, a salinidade e as concentrações de aditivos, considerando os efeitos futuros das decisões; (vi) desenvolvimento e avaliação de um estimador de estados baseado em redes neurais informadas pela física (PINNs), com assimilação de dados operacionais de pressão, vazão e temperatura, para inferir a evolução dos mecanismos de dano à formação e quantificar as incertezas das estimativas; acoplamento desse estimador ao agente de aprendizado por reforço (RL), de modo que as decisões sobre a composição da água sejam atualizadas dinamicamente conforme o estado estimado do poço; e (vii) validação experimental da política desenvolvida por RL, mediante aplicação da sequência de composições recomendada em ensaio de *coreflooding* e comparação entre a injetividade medida e a prevista pelo ambiente de simulação.

A avaliação incluirá a propagação das incertezas dos parâmetros, testes em cenários geológicos e geoquímicos não utilizados no treinamento e análise estatística do desempenho das políticas. Esperam-se como resultados modelos físicos calibrados, parâmetros de dano com incertezas quantificadas, evidências sobre as vantagens e limitações da otimização adaptativa e uma ferramenta computacional de apoio à decisão para recomendar composições de água específicas a diferentes cenários de reservatório. Como impactos potenciais, destacam-se a redução da perda de injetividade, da demanda energética de bombeamento e da necessidade de intervenções corretivas, favorecendo o reaproveitamento da água produzida e a eficiência operacional de campos petrolíferos.

Palavras-chave: injetividade; água de injeção; dano à formação; transporte reativo; redes neurais informadas pela física; aprendizado por reforço; otimização dinâmica.

1. Justificativa e diagnóstico da situação atual

A água produzida é o maior efluente líquido da produção de óleo e gás, com estimativa global superior a 250 milhões de barris por dia e volume crescente à medida que os campos amadurecem [1, 2]. É uma matriz formada pela água de formação e, em campos sob injeção, pela própria água injetada após a irrupção [3]. Sua reinjeção, isolada ou misturada à água do mar, é a destinação predominante em campos offshore maduros.

A composição dessa água define sua compatibilidade com o reservatório. Ela reúne eletrólitos monovalentes (Na^+, K^+, Cl^-), cátions divalentes formadores de incrustação (Ca^{2+}, Mg^{2+}, Ba^{2+}, Sr^{2+}, Fe^{2+}), ânions como ${SO_4}^{2-}$ e ${HCO_3}^-$ e gases dissolvidos como H_2S e CO_2 [4]. Quando a água injetada, rica em sulfato, encontra a água de formação rica em bário e estrôncio, a mistura ultrapassa o limite de solubilidade e precipita sulfatos, com destaque para o $BaSO_4$, cujo produto de solubilidade da ordem de 10^{-10} o torna praticamente irreversível depois de nucleado [5, 6]. A esse mecanismo somam-se a cristalização de halita em salmouras hipersalinas [7, 8], a transição gipsita–anidrita do $CaSO_4$ nas zonas de gradiente térmico [9], a migração de finos por redução de salinidade [10], a filtração profunda de sólidos e óleo [11] e o dano associado à atividade bacteriana.

O efeito integrado é a perda progressiva de permeabilidade no entorno do poço, com aumento do fator de película e queda do índice de injetividade [6, 12]. As consequências operam em três escalas: maior pressão de injeção e consumo elétrico das bombas; intervenções corretivas (acidificação, *scale squeeze*, *workover*) que retiram o poço de serviço e nem sempre restauram a permeabilidade original [13, 14]; e, a longo prazo, desbalanço da reposição de volume (*voidage replacement*), perda de pressão do reservatório e redução da recuperação final [3].

A relevância desse problema é particularmente evidente nos reservatórios offshore do estado do Rio de Janeiro, em que a reinjeção de água produzida e a utilização de água do mar tratada integram as estratégias de manejo de água e manutenção da pressão. Na Bacia de Campos, campos como Marlim, Albacora e Roncador apresentam

condições em que a compatibilidade entre as águas injetadas e a água de formação é um aspecto importante da operação, especialmente diante do risco de precipitação de sulfatos de baixa solubilidade, como o $BaSO_4$ [7, 15]. Em reservatórios do pré-sal, a elevada salinidade de determinadas águas de formação e a necessidade de gerir volumes expressivos de água produzida ampliam a importância de definir critérios de tratamento e reinjeção compatíveis com as características de cada sistema rocha–fluido.

Na prática, a especificação da água de injeção pode envolver limites de concentração de sulfato e de outros íons formadores de incrustação, salinidade e composição iônica, pH, teor de sólidos suspensos e sua distribuição de tamanho, concentração de óleo residual, oxigênio dissolvido, atividade microbiológica e dosagens de produtos químicos, como inibidores de incrustação, biocidas e sequestrantes de oxigênio. Também são definidas condições de tratamento, proporções de mistura entre fontes de água e faixas operacionais de vazão, pressão e temperatura. Embora esses controles sejam necessários, o atendimento individual a limites de qualidade não assegura, por si só, a preservação da injetividade: águas que satisfazem especificações em seus pontos de origem podem tornar-se incompatíveis após a mistura com a água de formação; alterações na salinidade e na razão entre cátions podem favorecer o desprendimento ou o inchamento de argilas; e pequenas concentrações de partículas ou óleo podem produzir retenção cumulativa em rochas com gargantas de poros mais estreitas. Além disso, a precipitação mineral, a filtração profunda e a formação de reboco modificam a permeabilidade ao longo do tempo, de modo que uma condição inicialmente aceitável pode deixar de sê-lo à medida que o dano se acumula e a composição das águas disponíveis varia. Consequentemente, a análise isolada de parâmetros físico-químicos ou a aplicação de limites fixos não representa necessariamente as interações entre água, rocha e operação, nem identifica a melhor decisão para preservar a injetividade durante toda a vida do poço.

A natureza multivariável, não linear e dependente do histórico dos mecanismos de dano à formação exige abordagens capazes de integrar informações geoquímicas, geológicas, petrofísicas e operacionais, superando a definição de limites independentes para os parâmetros de qualidade da água de injeção. Nesse contexto, a combinação de modelos físicos e inteligência artificial oferece uma estratégia para representar as interações entre esses mecanismos e antecipar os efeitos de diferentes condições de injeção. As redes neurais informadas pela física (PINNs) podem incorporar as equações de conservação e transporte à análise de dados experimentais e operacionais, permitindo identificar parâmetros de dano de difícil medição direta e estimar estados internos do sistema, com avaliação de suas incertezas. Por sua vez, algoritmos de aprendizado por reforço (RL), treinados em um ambiente de simulação física calibrado e computacionalmente acelerado, podem avaliar sequências de decisões sobre a composição química e a mistura de águas, considerando tanto as restrições operacionais quanto as consequências futuras do dano acumulado. O acoplamento entre a estimação de estados por PINNs e a otimização sequencial por RL possibilita atualizar as recomendações à medida que novas informações operacionais se tornam disponíveis. Espera-se, assim, estabelecer uma metodologia de apoio à decisão mais adaptativa e fundamentada fisicamente, com potencial para preservar a injetividade, reduzir o consumo energético de bombeamento e a necessidade de intervenções corretivas, e ampliar o aproveitamento da água produzida.

2. Estado da arte

Na literatura recente, a inteligência artificial (IA) aplicada à injeção de água de baixa salinidade ou composição ajustada (*low-salinity/engineered water injection*) concentra-se, em grande parte, na previsão de recuperação de petróleo a partir das interações entre água, rocha e óleo. Na revisão de Arain et al. [16], são discutidos mecanismos como troca iônica multicomponente, alteração de molhabilidade, dissolução mineral e migração de finos, bem como aplicações de redes neurais artificiais, máquinas de vetores de suporte e métodos baseados em árvores. A revisão ressalta que o efeito da salinidade não é universal: as respostas dependem da mineralogia, da composição iônica, das condições operacionais e do histórico de interação entre os fluidos e a rocha.

Shafiei et al. [17] compararam diferentes algoritmos para prever o desempenho da injeção de água de baixa salinidade em carbonatos, com base em dados experimentais, conforme sintetizado por Arain et al. [16]. Tatar et al. [18] avaliaram modelos orientados por dados em arenitos, incluindo variáveis de composição iônica e propriedades do sistema rocha–fluido. Kondori et al. [19] examinaram modelos conexionistas híbridos para estimar o desempenho da injeção de água de baixa salinidade, considerando, entre outros atributos, salinidade, vazão, temperatura e permeabilidade. Em todos esses casos, as variáveis químicas são relevantes, mas os indicadores preditos dizem respeito principalmente à recuperação de óleo, não à evolução do índice de injetividade causada pelo dano próximo ao poço.

A revisão de Arain et al. [16] também apresenta estudos apoiados em dados sintéticos produzidos por simuladores. Esse procedimento permite explorar espaços de parâmetros extensos, mas a precisão obtida sobre dados gerados pelo mesmo modelo não demonstra, por si só, capacidade de generalização para formações heterogêneas e operações reais. Para o problema da injetividade, essa distinção é particularmente importante: prever corretamente o fator de recuperação não equivale a prever deposição mineral, desprendimento de finos, obstrução de gargantas de poros ou perda de permeabilidade em torno do injetor.

Partindo dessa capacidade preditiva, a pesquisa passou também a investigar a seleção computacional de condições de injeção mais favoráveis. Reginato et al. [20] aplicaram uma abordagem híbrida com agrupamento e redes neurais à previsão de alterações de permeabilidade relativa durante a injeção de água de composição ajustada em

carbonatos, apoiando análises de desenvolvimento do reservatório. Mercado Sierra et al. [21] estudaram estratégias de injeção de água de baixa salinidade no campo de Namorado com simulação composicional e otimização sob incerteza geológica. Uma abordagem baseada em modelo substituto neural e otimização por enxame de partículas também foi considerada na seleção de salinidade, concentração de polímero e condições de injeção [22]. Nesses antecedentes, a composição da água integra o espaço de variáveis analisadas, porém a função objetivo está associada principalmente ao desempenho da recuperação ou a métricas econômicas.

Essa distinção não implica oposição entre recuperação e injetividade. Ao contrário, uma especificação operacionalmente útil deve minimizar o dano à formação sem desconsiderar os requisitos de produção do reservatório. O foco do presente projeto é a preservação da capacidade de injeção: a composição selecionada deve limitar precipitação de $BaSO_4$, $SrSO_4$ e outros sais, instabilidade de argilas, retenção de sólidos e óleo e os efeitos cumulativos desses processos. Diferentemente de uma busca estática pela melhor salinidade, a decisão poderá ser atualizada quando mudarem a composição das águas disponíveis, a operação ou o estado estimado de dano.

A aplicação operacional dessas estratégias depende, por sua vez, de representar adequadamente a heterogeneidade do reservatório e as condições efetivas dos poços. Nesse sentido, métodos de IA vêm sendo empregados para integrar observações geológicas estáticas e registros operacionais dinâmicos. Yuan et al. [23] desenvolveram, para um projeto de combustão *in situ* em Hongqian, Xinjiang, um modelo híbrido geológico–dinâmico de conectividade entre poços injetores e produtores. A abordagem combina similaridade entre perfis geofísicos, seleção de atributos por aprendizado de máquina e variáveis de operação e produção; sua avaliação foi confrontada com tendências de produção e ensaios com traçadores. O estudo trata de *injeção de ar e conectividade interpoços*, não de otimização da composição de água nem de incrustação. Seu interesse metodológico para esta proposta reside na integração de dados heterogêneos e na seleção de variáveis relevantes para caracterizar sistemas de reservatório.

Essa integração sugere uma extensão útil à avaliação da injetividade. Propriedades da rocha, perfis geofísicos, condições de completação e históricos de pressão e vazão contêm informações complementares, mas nem sempre permitem observar diretamente os depósitos e a evolução radial da permeabilidade. Torna-se necessário empregar modelos físicos e métodos de assimilação de dados que distingam, quando possível, alterações da pressão do reservatório e perdas de mobilidade de danos localizados no entorno do poço. A conectividade interpoços pode contribuir futuramente com o contexto operacional, sem substituir a caracterização dos mecanismos físico-químicos de dano.

Uma vez caracterizadas as condições físico-químicas e operacionais, a seleção da água deixa de ser apenas um problema preditivo e passa a exigir decisões ao longo do tempo. O aprendizado por reforço (RL) permite representar essas escolhas como uma sequência em que ações presentes afetam o estado e os resultados futuros. Estudos já investigaram algoritmos de RL para controlar vazões e coordenar operações de injeção e produção, incluindo abordagens com agentes múltiplos, informadas pela física e com modelos substitutos [24–26]. Mesmo nos trabalhos em que a ação do agente inclui o tipo ou a concentração do fluido injetado, como a escolha entre água e gás na injeção alternada [27] ou a concentração de agentes de controle de perfil [28], o objetivo é a recuperação de óleo. Fora da indústria do petróleo, o RL tem sido aplicado à dosagem de produtos químicos em estações de tratamento de água [29, 30], o que indica sua adequação a decisões sobre a composição química da água. Nenhum desses trabalhos, entretanto, trata da seleção sequencial da composição iônica da água de injeção para prevenir o dano à formação.

A combinação de simuladores de transporte reativo com modelos substitutos de aprendizado profundo é promissora nesse cenário. Um simulador físico pode representar transporte de espécies, precipitação, retenção de partículas e evolução da permeabilidade, enquanto um substituto treinado em simulações calibradas aproxima as transições de estado necessárias a numerosos episódios de RL. Sua utilização exige validação em cenários não vistos e verificações periódicas no simulador original, pois o agente pode explorar imprecisões do modelo substituto. A incerteza das previsões também precisa informar as restrições e a avaliação de segurança das ações recomendadas.

A eficácia da otimização sequencial depende ainda de identificar parâmetros de dano e inferir estados internos que não são medidos diretamente. Para esses problemas inversos, as redes neurais informadas pela física (PINNs) constituem uma alternativa em que dados experimentais ou operacionais são combinados a equações de conservação e transporte [31]. No projeto proposto, sua utilização será investigada em duas funções distintas: identificar parâmetros físico-químicos e constitutivos do dano a partir de ensaios de *coreflooding*; e investigar a estimação de estados não diretamente observáveis a partir de históricos de pressão, vazão e temperatura, com assimilação de dados. As estimativas e suas incertezas serão fornecidas ao agente de RL para condicionar a atualização das decisões ao estado provável do poço. A viabilidade dessa etapa depende da identificabilidade dos mecanismos e será comparada a métodos convencionais de calibração e assimilação, especialmente em regimes com frentes abruptas ou dados escassos.

Em conjunto, os trabalhos examinados demonstram avanços em três direções complementares: (i) previsão por IA dos efeitos da salinidade e da composição iônica sobre propriedades de fluxo e recuperação de petróleo; (ii) otimização computacional de variáveis químicas e operacionais com foco sobretudo em recuperação ou retorno econômico; e (iii) integração de dados geológicos e operacionais e aplicação de RL a decisões sucessivas de injeção e produção. Entretanto, os estudos aqui analisados não estabelecem uma metodologia experimentalmente validada

que selecione *ao longo do tempo a composição físico-química e as proporções de mistura da água*, tendo como objetivo explícito a *preservação da injetividade* e considerando conjuntamente os mecanismos acumulativos de dano e a incerteza sobre o estado do poço.

A contribuição proposta é integrar um simulador físico de transporte reativo e dano à formação, PINNs para identificação de parâmetros e estimação de estados, um modelo substituto para acelerar a simulação e algoritmos de RL com restrições para otimização dinâmica da água de injeção. O ganho da decisão sequencial será comparado com especificações convencionais, composições fixas e reotimização periódica, com avaliação experimental por *coreflooding*.

3. Trajetória do proponente e aderência ao projeto

A formação do proponente, integralmente realizada na Universidade Federal de Minas Gerais (UFMG), da graduação em Engenharia Mecânica ao doutorado, e a atuação posterior na COPPE/UFRJ reúnem três competências que este projeto integra: experimentação em sistemas termofluidos, inteligência artificial aplicada ao controle de sistemas dinâmicos e tratamento de água de produção na indústria de óleo e gás. Cada etapa dessa trajetória acrescentou um elemento à metodologia aqui proposta.

A base experimental foi construída no mestrado, dedicado à investigação do coeficiente de transferência de calor na condensação do fluido refrigerante de baixo impacto ambiental R1234yf. O trabalho exigiu projetar e operar uma bancada instrumentada, tratar dados experimentais e avaliar a incerteza de medição das grandezas derivadas, competências que agora sustentam o desenho dos ensaios de *coreflood* (etapas 3 e 7) e o tratamento metrológico dos parâmetros identificados (Seção 6).

No doutorado, o foco passou da medição à decisão. A pesquisa desenvolveu estratégias de controle de máquinas térmicas em que algoritmos preditivos de inteligência artificial determinam os ganhos do controlador a partir do comportamento previsto do sistema. A questão central já era a mesma que este projeto retoma em outro domínio: como um modelo aprendido a partir de dados pode orientar decisões sucessivas sobre um sistema não linear, cuja resposta depende do histórico de operação. O aprendizado por reforço proposto representa a extensão natural dessa linha, pois, em vez de ajustar os ganhos de um controlador, o agente aprende diretamente a política de decisão sobre a composição da água de injeção, considerando os efeitos futuros de cada ação.

O contato com o problema da injetividade veio com o pós-doutorado no Programa de Engenharia Mecânica da COPPE/UFRJ, iniciado em 2024 e voltado ao tratamento de água de produção por membranas e ao desenvolvimento dos sistemas de controle desses processos, com um artigo sobre um *framework* de seleção de membranas atualmente em revisão. Essa atuação levou a pesquisa para a área de óleo e gás e evidenciou uma questão que o tratamento, isoladamente, não resolve: qual água deve ser injetada para preservar a injetividade do poço ao longo de sua vida útil.

A proposta resulta, portanto, da convergência dessas três frentes e inaugura uma linha de pesquisa própria, na qual a experiência em medição e incerteza orienta os ensaios, a experiência em controle baseado em inteligência artificial fundamenta o agente de decisão e a atuação com água de produção define o problema de aplicação. A produção científica completa consta do Currículo Lattes anexado.

4. Questão científica, tecnológica ou de inovação e hipóteses

Questão: é possível determinar, de forma adaptativa ao longo da vida do poço, a composição química ótima da água de injeção que preserva a injetividade, dadas as propriedades da rocha, as águas disponíveis (formação, produzida e do mar) e as condições operacionais, mesmo quando parte dos parâmetros que governam o dano não é medida diretamente?

Hipótese 1 (identificabilidade). Os parâmetros do dano que não são medidos rotineiramente (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas de desprendimento de finos) são identificáveis a partir de ensaios de deslocamento com medição de pressão na entrada, na saída e em tomadas intermediárias ao longo do plugue, por meio de redes neurais informadas por física (PINN) em formulação inversa; o modelo calibrado prevê etapas de injeção não usadas na calibração com erro inferior a 15% [32].

Hipótese 2 (científica). A perda de injetividade de poços injetores resulta de mecanismos de dano acoplados (incrustação, migração de finos, filtração, dano biológico), cuja resposta depende conjuntamente da composição da água, das propriedades da rocha (mineralogia, teor de argilas, estrutura porosa) e das condições operacionais (vazão, pressão e temperatura), e é cumulativa ao longo do tempo. Consequentemente: (a) as condições ótimas da água não podem ser definidas por limites independentes para cada parâmetro, como fazem os critérios empíricos atuais; e (b), no ambiente de simulação calibrado experimentalmente, uma política de RL condicionada ao estado da rocha, da operação e do dano acumulado preserva a injetividade de forma significativamente superior à reotimização periódica míope, que escolhe a cada período a melhor condição para o momento atual sem considerar suas consequências futuras.

Critérios de refutação: (a) se condições definidas por limites independentes atingirem desempenho equivalente ao da política, o acoplamento entre mecanismos não é relevante na prática; (b) se a política não superar a reotimização míope em pelo menos 5% [33] nos cenários avaliados, a dependência da trajetória não é relevante, e a otimização estática periódica é suficiente.

Hipótese 3 (validação experimental). A sequência de composições recomendada pela política, transposta para a escala de laboratório e aplicada em coreflood, mantém a injetividade medida acima do limite de intervenção $\alpha_{\min}$ (fixado em 0,8 na escala de laboratório), e o ambiente de simulação prevê essa injetividade com erro inferior a 15% [32]. *Critério de refutação:* se a injetividade medida cair abaixo de $\alpha_{\min}$ ou o erro exceder 15%, o ambiente não é confiável para decidir fora da faixa em que foi calibrado.

As hipóteses são encadeadas: a Hipótese 1 fornece parâmetros calibrados e sua incerteza; a Hipótese 2 usa esses parâmetros para testar, no ambiente calibrado, o valor da decisão sequencial; a Hipótese 3 verifica experimentalmente a confiabilidade desse ambiente, isto é, se as decisões tomadas em simulação se sustentam no meio poroso real. Se a Hipótese 1 for apenas parcialmente confirmada, a Hipótese 2 continua testável, com incerteza paramétrica maior incorporada ao treinamento do agente.

5. Objetivos

5.1 Objetivo geral

Desenvolver e validar uma metodologia que combine modelagem física do dano à formação, identificação de parâmetros por redes neurais informadas por física e aprendizado por reforço profundo para determinar dinamicamente a composição química ótima da água de injeção, de modo a mitigar a incrustação, a migração de argilas e os demais mecanismos de dano que comprometem a injetividade, e validar experimentalmente essas decisões em ensaios de coreflood.

5.2 Objetivos específicos

OE1. Construir uma base de dados integrada de composição de águas, propriedades de rocha, variáveis operacionais e injetividade, a partir da literatura, de dados públicos de campo e dos ensaios do projeto.

OE2. Desenvolver um simulador radial multiespécie do dano (incrustação, finos e argilas, filtração e reboco, dano biológico), capaz de separar o dano real da queda aparente por pressurização do reservatório.

OE3. Realizar análise de sensibilidade global do simulador para identificar os parâmetros que mais afetam a injetividade e a decisão, e definir um conjunto mínimo de caracterização por rocha.

OE4. Projetar e executar ensaios de deslocamento no LRAP+ e identificar os parâmetros não medidos por PINN em formulação inversa, com quantificação de incerteza e validação cega (teste da Hipótese 1).

OE5. Desenvolver um modelo substituto informado por física, parametrizado pelas propriedades da rocha, pelas condições operacionais e pelas ações, que sirva de ambiente rápido de treinamento.

OE6. Treinar um agente de RL com restrições, robusto à incerteza paramétrica, que determine ao longo da vida do poço a composição da água de injeção, incluindo as concentrações de aditivos, e compará-lo com as referências definidas (teste da Hipótese 2).

OE7. Desenvolver um estimador do dano em operação, alimentado por dados de pressão e vazão de poços, e testá-lo com dados públicos de campo.

OE8. Validar a política em ensaios de coreflood no LRAP+, publicar a metodologia em artigos científicos e na tese de doutorado e integrar simulador, modelos e agentes em uma ferramenta de apoio à decisão (teste da Hipótese 3).

6. Metodologia

A metodologia é organizada em sete etapas encadeadas: simulação física (1), sensibilidade (2), calibração experimental por PINN inversa (3), modelo substituto (4), treinamento e avaliação dos agentes acoplados ao ambiente de simulação (5), estimação com dados de campo (6) e validação experimental da política com desenvolvimento do software (7). O trabalho é computacional, exceto as duas campanhas de coreflood no LRAP+ (etapas 3 e 7). A Figura 1 resume os fatores considerados e sua relação com o ciclo de decisão.

6.1 Formulação: decisão sequencial sob observação parcial

A escolha da água é formulada como um processo de decisão de Markov parcialmente observável. Em cada período t (dias a semanas), o estado do sistema é

$$s_t = (\theta,\ w_t,\ o_t,\ d_t)\,, \tag{1}$$

em que θ reúne as propriedades da rocha e do poço (mineralogia, tipo e teor de argilas, capacidade de troca catiônica, porosidade, permeabilidade, distribuição de gargantas, completação) e os parâmetros do dano; w_t, a composição das águas disponíveis (cátions, ânions, salinidade, pH, gases dissolvidos, óleo, sólidos e atividade microbiológica); o_t, as condições operacionais (vazão e temperatura de injeção, pressões de cabeça e de fundo, pressão média do reservatório); e d_t, o dano acumulado e sua distribuição radial. Parte de θ e todo d_t não são observados diretamente e são estimados (etapas 3 e 6).

A ação a_t define a composição química da água injetada: razão de mistura entre água produzida e água do mar, teor de sulfato, salinidade, razão Na^+/Ca^{2+} e demais teores iônicos, além das concentrações de aditivos (inibidor de incrustação, biocida e sequestrante de oxigênio). A vazão e a temperatura de injeção fazem parte das condições operacionais o_t e não são variáveis de decisão, e os processos de tratamento necessários para obter a composição

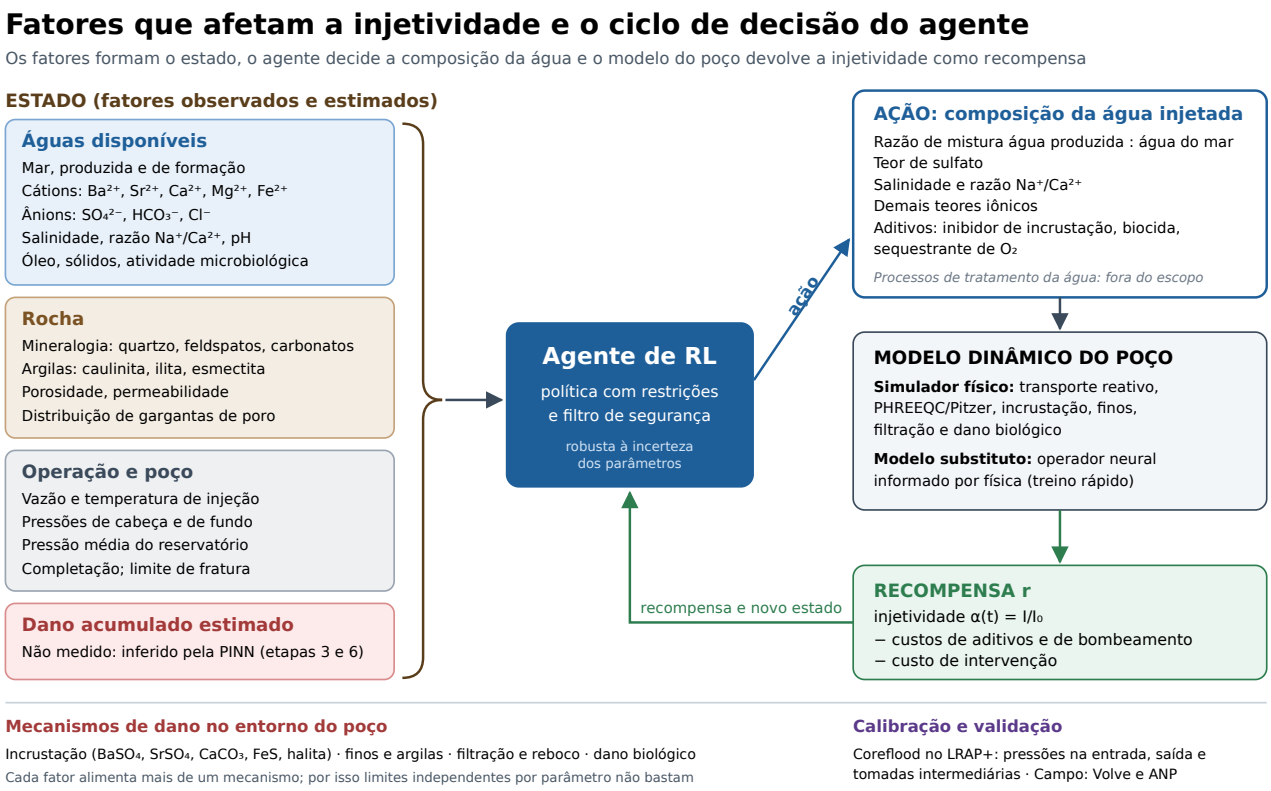


Figura 1: Fatores que afetam a injetividade e sua relação com a metodologia: os fatores formam o estado do agente, a composição da água injetada é a ação, o modelo dinâmico do poço calcula o dano e a injetividade retorna como recompensa.

recomendada estão fora do escopo do agente. A recompensa combina a manutenção da injetividade com os custos:

$$r_t = \alpha(t) - c_{\text{adit}}(a_t) - c_{\text{bomb}}(\Delta P_t) - c_{\text{int}}\,\mathbb{1}[\alpha(t) < \alpha_{\min}], \tag{2}$$

e o agente busca a política π que maximiza o retorno esperado sob as restrições $g_k(s_t, a_t) \le 0$:

$$\max_{\pi}\ \mathbb{E}_{\theta\sim p(\theta|\mathcal{D})}\ \mathbb{E}_{\pi}\left[\sum_{t=0}^{T}\gamma^t r_t\right] \quad \text{s.a.} \quad g_k(s_t, a_t) \le 0. \tag{3}$$

As restrições g_k incluem índices de saturação, salinidade e velocidade críticas para estabilidade das argilas, pressão de fratura (manutenção do regime matricial), faixas admissíveis de dosagem dos aditivos e limites de composição atingíveis a partir das águas disponíveis. A esperança sobre $p(\theta \mid \mathcal{D})$ incorpora a incerteza dos parâmetros identificados na etapa 3. Nesta pesquisa, a recompensa se limita à preservação da injetividade e aos custos e restrições associados. A interface para acoplamento futuro de modelos de recuperação de petróleo é descrita na etapa 7.

6.2 Etapa 1 – Modelo físico do dano

O simulador parte das formulações clássicas de filtração profunda [11, 34] e de precipitação de sulfatos em misturas de águas incompatíveis [6] e incorpora: (i) geometria radial no entorno do poço, com completação canhoneada ou em poço aberto; (ii) química multiespécie via PHREEQC com modelo de Pitzer ($BaSO_4$, $SrSO_4$, $CaSO_4$, $CaCO_3$, halita e FeS), incluindo a variação de temperatura e pressão ao longo da coluna e o aporte de ferro por corrosão; (iii) cinética de precipitação de segunda ordem na supersaturação [35], com tempo de indução e efeito da concentração de inibidor de incrustação; (iv) migração e inchamento de argilas em função da salinidade, da composição catiônica e da velocidade; (v) filtração profunda e reboco externo de sólidos e gotas, dependentes da razão entre o tamanho das partículas e o das gargantas [11, 34]; (vi) módulo de dano biológico, com efeito da concentração de biocida; e (vii) acoplamento com um modelo simplificado de reservatório, para separar o dano no entorno do poço da queda aparente de injetividade por aumento da pressão média e redução de mobilidade. O núcleo do simulador são a incrustação, a migração de finos e a filtração; os módulos de dano biológico e de acoplamento com o reservatório são incorporados de forma incremental. O simulador é verificado por balanço de massa e por reprodução de casos da literatura.

6.3 Etapa 2 – Análise de sensibilidade global

O simulador depende de dezenas de parâmetros, parte dos quais não é medida rotineiramente, como os coeficientes de filtração e de dano, as constantes cinéticas e a salinidade crítica de desprendimento de finos. Calibrar todos eles experimentalmente exigiria um número de ensaios inviável. Por isso, antes dos ensaios, a análise de sensibilidade global identifica quais parâmetros de fato influenciam a resposta do sistema, variando-os simultaneamente em suas faixas plausíveis ao longo de milhares de simulações.

A análise é feita em dois passos. Primeiro, a triagem de Morris [36], de baixo custo computacional, separa os parâmetros com efeito relevante daqueles com efeito desprezível, que são descartados. Em seguida, os índices de Sobol [37], calculados apenas para os parâmetros remanescentes, quantificam a fração da variação da resposta atribuível a cada parâmetro, isoladamente e em interação com os demais.

Além da razão de injetividade $\alpha(t)$, a análise considera saídas que afetam diretamente a decisão sobre a água: se a ordenação entre as águas candidatas se mantém quando um parâmetro varia e quanto se deslocam as curvas de decisão, como o sulfato residual máximo que mantém $\alpha \geq 0{,}8$. Um parâmetro que altera a injetividade, mas não altera a escolha da água, tem menor prioridade de calibração do que um que inverte essa escolha.

Os resultados orientam as etapas seguintes: definem quais parâmetros devem ser calibrados nos ensaios da etapa 3, quais podem ser fixados em valores da literatura, qual é o conjunto mínimo de medições necessário para caracterizar uma nova rocha e quais variáveis podem ser retiradas do estado do agente, reduzindo o custo de treinamento do aprendizado por reforço.

6.4 Etapa 3 – Ensaios no LRAP+ e identificação por PINN inversa

Desenho dos ensaios. Antes de cada campanha, uma análise de identificabilidade (perfis de verossimilhança sobre dados sintéticos do simulador) define quais medições distinguem os parâmetros de interesse. Sabe-se, por exemplo, que a queda de pressão total não separa o coeficiente de filtração do coeficiente de dano, o que exige tomadas de pressão intermediárias [34]. O porta-testemunho do LRAP+ dispõe de tomadas intermediárias por capilares ao longo do plugue, o que permite medir o perfil de pressão e localizar o dano. Os ensaios serão realizados em plugs de arenito de afloramento, caracterizados por porosidade e permeabilidade (DV-4000), com mineralogia obtida da caracterização disponível na literatura para a rocha selecionada, e com salmouras sintéticas de composição controlada. O programa experimental contratado compreende dois ensaios, um em cada campanha. O ensaio da primeira campanha é conduzido em múltiplas etapas no mesmo plugue, cada uma com uma salmoura de composição diferente, definidas pela análise de identificabilidade para ativar sucessivamente os mecanismos de interesse (compatibilidade e incrustação, redução escalonada de salinidade para finos). As etapas de incrustação usam salmouras isentas de partículas, de modo que o dano medido seja atribuído à precipitação, localizada pelas tomadas intermediárias. Ao longo de todo o ensaio são registradas a vazão e as pressões absolutas e diferenciais na entrada, na saída e nas tomadas intermediárias. As etapas iniciais são usadas na calibração e as finais, no teste cego da Hipótese 1; o segundo ensaio é dedicado à validação da política (etapa 7). Ensaios adicionais realizados em colaboração com o LRAP+, quando viabilizados, serão incorporados aos conjuntos de calibração e de teste.

PINN inversa. Uma rede neural representa os campos de concentração, de depósito e de pressão $\hat{u}(x,t)$ e é treinada para satisfazer simultaneamente os dados e as equações do modelo [31]:

$$\mathcal{L}(\phi_{\mathrm{NN}}, \theta) = \lambda_d \, \mathcal{L}_{\mathrm{dados}} + \lambda_r \, \mathcal{L}_{\mathrm{EDP}} + \lambda_b \, \mathcal{L}_{\mathrm{contorno}}, \tag{4}$$

em que os parâmetros desconhecidos θ (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas) são variáveis treináveis. Onde a forma da lei constitutiva é incerta, como $k(\sigma)$, uma pequena rede aprende a própria relação. A incerteza é estimada por conjuntos de redes ou formulação bayesiana, resultando em $p(\theta \mid \mathcal{D})$. Como PINNs têm dificuldade com frentes abruptas em transporte em meios porosos [38], serão usadas ponderação adaptativa das perdas, treinamento progressivo no tempo e difusão artificial controlada, e os resultados serão comparados com a calibração clássica por mínimos quadrados sobre o simulador de volumes finitos.

Validação cega (Hipótese 1). O modelo calibrado com as etapas iniciais prevê, sem novo ajuste, a resposta às etapas finais, de composições diferentes, e compara-se a injetividade e o perfil de pressão ao longo do plugue.

6.5 Etapa 4 – Modelo substituto

O agente exige milhares de episódios, o que torna inviável usar o simulador completo como ambiente. Será treinado um operador neural (DeepONet ou FNO) [39, 40], com resíduo físico na função de perda, que recebe θ, o estado e a sequência de ações e devolve a evolução do dano e de $\alpha(t)$. Os dados de treino são gerados pelo simulador, com amostragem por hipercubo latino sobre $p(\theta \mid \mathcal{D})$ e sobre o espaço de operação. A validação usa simulações não vistas, com metas de R^2, erro em α e ganho de tempo de avaliação, e a incerteza do substituto é estimada por conjunto de redes, para que o agente evite regiões em que o substituto não é confiável.

6.6 Etapa 5 – Agente de aprendizado por reforço

O agente é treinado sobre o substituto, com verificação periódica no simulador completo. Como nenhum algoritmo é superior em todos os problemas, serão avaliadas as oito famílias de aprendizado por reforço, cada uma com um papel definido no projeto (Tabela 1).

Tabela 1: Famílias de algoritmos de RL avaliadas, seu uso no projeto e aplicações de referência.

Família e algoritmos	Uso no projeto	Aplicações
Tabulares: iteração de política e de valor, Monte Carlo, TD(0), TD(λ), SARSA, Q-learning	Versão discretizada e reduzida do problema (poucas águas candidatas, estados agregados). A iteração de valor fornece o ótimo exato dessa versão, usado como gabarito para verificar os métodos profundos.	[27, 29, 41, 42]
Valor com redes neurais: DQN, Double DQN, C51, QR-DQN, Rainbow	Ações discretas (catálogo de composições candidatas). As versões distribucionais (C51, QR-DQN) estimam a distribuição do retorno e permitem políticas sensíveis a risco, avaliadas pelo CVaR.	[43–45]
Gradiente de política: REINFORCE, gradiente natural, TRPO	Referências de base para ações contínuas; o TRPO fundamenta a otimização com restrições por região de confiança (CPO) [46].	[47, 48]
Ator-crítico: A2C, A3C, DDPG, TD3, SAC, PPO	Candidatos principais para ações contínuas (proporções de mistura, teores iônicos e concentrações de aditivos), em versões com restrições por multiplicadores de Lagrange [49].	[26, 28, 50–52]
Baseados em modelo: Dyna-Q, PILCO, PETS, MBPO, Dreamer, MuZero	Usam o substituto para gerar transições e reduzir chamadas ao simulador. PILCO e PETS são eficientes quando cada amostra é cara, como no ajuste ao ambiente em escala de laboratório (etapa 7); o Dreamer, com modelo latente, trata a observação parcial.	[30, 53–55]
Multiagente: Q-learning independente, MADDPG, VDN, QMIX, MAPPO	Dois usos: vários poços injetores que compartilham as mesmas fontes de água; e um agente por grupo de variáveis de composição (mistura, salinidade, teores iônicos, aditivos), coordenados.	[25, 56, 57]
Offline: BCQ, CQL, IQL, AWAC, TD3+BC	Aprendizado a partir de históricos de operação já registrados, sem experimentação no poço; política inicial conservadora.	[58–60]
Hierárquicos: opções, MAXQ, HIRO	Correspondem à hierarquia do problema: o nível alto escolhe a composição-alvo (semanas a meses) e o nível baixo ajusta as proporções de mistura dentro de cada período.	[61–63]

O núcleo do estudo é formado pela iteração de valor (gabarito), pelo PPO com restrições, pelo SAC e por um método baseado em modelo; as demais famílias entram na triagem conforme o orçamento computacional permitir. A avaliação é feita em dois estágios:

(a) *Triagem:* um ou dois representantes de cada família são treinados em um ambiente reduzido (horizonte curto, menos cenários, três sementes). Na versão discretizada, o desempenho é normalizado pelo ótimo exato da iteração de valor. Os critérios para avançar são o retorno normalizado, a taxa de violação de restrições, a eficiência amostral (retorno por chamada ao simulador) e o custo computacional.

(b) *Aprofundamento:* os três ou quatro melhores da triagem, mais o PPO com restrições como referência fixa, seguem para o protocolo estatístico completo da Seção 6.7.

Os métodos multiagente e hierárquicos são avaliados nos cenários em que se aplicam (vários poços e vários grupos de variáveis de composição), e os métodos *offline* são avaliados por avaliação fora da política sobre históricos simulados e públicos. Cada algoritmo é testado com observação completa e em versão recorrente (LSTM), e os hiperparâmetros são ajustados com o mesmo orçamento para todos, usando bibliotecas de referência (Stable-Baselines3, OmniSafe e d3rlpy). A robustez à incerteza é obtida sorteando $\theta \sim p(\theta \mid \mathcal{D})$ a cada episódio, de modo que a política funcione em toda a faixa plausível dos parâmetros, e não apenas no valor médio [24]. A observação parcial é tratada fornecendo à política a estimativa do estado latente produzida pelo estimador da etapa 6, ou por meio de uma política recorrente. Um filtro de segurança projeta as ações propostas na região viável definida pelas restrições g_k.

Para testar a Hipótese 2, a política é comparada, nos mesmos cenários de rocha, água e operação, com três referências: (i) os critérios empíricos atuais, baseados em limites independentes por parâmetro; (ii) a melhor condição fixa para todo o horizonte, obtida por otimização bayesiana; e (iii) a reotimização periódica míope, em que a otimização bayesiana é reaplicada a cada período com as condições do momento. A referência (iii) é a principal, pois isola o ganho atribuível à antecipação das consequências futuras. As métricas são a injetividade média e final no horizonte, o custo total, o número de violações de restrição e a ordenação das alternativas. O protocolo estatístico de comparação está na Seção 6.7.

6.7 Quantificação de incerteza e critérios estatísticos

Incerteza dos parâmetros identificados pela PINN (Hipótese 1). A incerteza de cada parâmetro θ_j será avaliada segundo o Guia para a Expressão da Incerteza de Medição (GUM) [64] e seu Suplemento 1 [65], com as componentes:

Componente	Fonte	Avaliação
Tipo A, repetibilidade	Variação das pressões em períodos de regime permanente de cada etapa e, quando disponíveis, entre ensaios adicionais	$u_A = s/\sqrt{n}$ a partir das leituras ou das estimativas de θ_j
Tipo A, estimação	Variabilidade do próprio estimador (inicialização e dados)	Conjunto de PINNs treinadas com sementes diferentes [66] e *bootstrap* dos resíduos [67]
Tipo B, instrumentos	Transdutores de pressão, bomba, temperatura, dimensões e porosidade do plug	Certificados de calibração e especificações, com distribuições normal ou retangular
Tipo B, modelo	Escolha da lei constitutiva (aditiva, porosidade crítica, aprendida)	Dispersão entre as estimativas obtidas com leis alternativas

Os coeficientes de sensibilidade $c_i = \partial\theta_j/\partial x_i$ às grandezas de entrada são obtidos por diferenciação automática da própria PINN, e a incerteza padrão combinada é

$$u_c(\theta_j) = \sqrt{u_A^2 + \sum_i c_i^2\, u_{B,i}^2 + u_{\text{mod}}^2 + 2\sum_{i<k} c_i c_k\, u(x_i, x_k)}, \tag{5}$$

com graus de liberdade efetivos pela fórmula de Welch-Satterthwaite e incerteza expandida $U = k\,u_c$, com k da distribuição t para 95% de abrangência. Como o modelo é não linear, o resultado será confrontado com a propagação por Monte Carlo do Suplemento 1, repetindo a identificação sobre o substituto para obter a distribuição de θ_j, seu intervalo de 95% e a covariância entre parâmetros; a formulação bayesiana da PINN [68] serve como verificação independente. A identificabilidade é verificada por perfis de verossimilhança [69].

Demonstração estatística da Hipótese 1. Três testes, em sequência:

(i) *Recuperação em dados sintéticos:* cerca de 200 conjuntos gerados pelo simulador com θ conhecido e ruído compatível com as incertezas tipo A e tipo B; o método deve ser não enviesado (teste t sobre o erro) e seus intervalos de 95% devem conter o valor verdadeiro em proporção compatível com 95% (teste binomial).

(ii) *Concordância com a calibração clássica:* as estimativas da PINN e do ajuste por mínimos quadrados sobre o simulador de volumes finitos devem ser compatíveis dentro das incertezas expandidas.

(iii) *Previsão cega:* para cada etapa de teste, o erro normalizado $E_n = |y_{\text{prev}} - y_{\text{med}}|/\sqrt{U_{\text{prev}}^2 + U_{\text{med}}^2}$ deve satisfazer $E_n \leq 1$ [70], e a calibração das incertezas previstas é verificada pela cobertura empírica dos intervalos e pelo histograma da transformada integral de probabilidade.

Comparação entre algoritmos de RL e teste da Hipótese 2. O desempenho de algoritmos de RL varia muito entre sementes aleatórias [71]. Cada algoritmo será treinado com pelo menos 10 sementes e avaliado em um conjunto de cenários de teste não usados no treino, com θ sorteado por Monte Carlo de $p(\theta \mid \mathcal{D})$. A incerteza paramétrica é propagada à decisão: para cada política, obtém-se a distribuição de $\alpha(T)$ e do custo, reportando mediana, quantis P10 e P90 e o valor em risco condicional (CVaR) dos 10% piores cenários. A agregação segue as recomendações de Agarwal et al. [72]: média interquartil (IQM) do retorno normalizado, intervalos de confiança de 95% por *bootstrap* estratificado sobre sementes e cenários, perfis de desempenho e probabilidade de melhoria entre pares de algoritmos. Comparações pareadas (mesmos cenários) usam o teste de postos sinalizados de Wilcoxon [73] com correção de Holm [74] para múltiplas comparações. O algoritmo escolhido é o de maior IQM cujo intervalo de confiança não se sobreponha ao dos demais, ou, havendo sobreposição, o de menor taxa de violação de restrições e menor CVaR. A Hipótese 2 é considerada confirmada se a probabilidade de melhoria da política sobre a reotimização míope tiver intervalo de 95% acima de 0,5 e o ganho mediano superar 5%.

6.8 Etapa 6 – Estimação em operação e validação com dados de campo

A mesma formulação inversa da etapa 3 é aplicada a dados de poço para estimar a evolução do dano e ajustar os parâmetros de cada poço. A separação entre dano e pressurização usa os dados de pressão de fundo e vazão, com análise do gráfico de Hall e de períodos de fechamento. O estimador é testado com os dados diários públicos do campo de Volve (Equinor), que incluem pressão de fundo, pressão de cabeça e volumes injetados, e as séries de injeção da ANP são usadas para testar a generalização do substituto a históricos de longo prazo. A incerteza do estimador permite ainda avaliar o valor da informação, isto é, quando vale a pena coletar uma nova medição antes de mudar a água.

6.9 Etapa 7 – Validação experimental da política e software

O teste final é experimental e verifica se as decisões tomadas no ambiente de simulação se sustentam no meio poroso real. Como o horizonte de vida do poço não cabe em um ensaio, a política é avaliada em escala de laboratório: o ambiente de simulação é reconfigurado com a geometria linear, as dimensões dos plugs e a faixa de vazões do coreflood, calibrado com os dados da primeira campanha, e o agente é ajustado nesse ambiente. No ensaio da segunda campanha, um plugue da mesma rocha recebe a sequência de composições recomendada pela política de RL. A sequência e a previsão do ambiente para $\alpha(t)$ são definidas e registradas antes do ensaio, para que a comparação seja cega em relação aos resultados. Medem-se $\alpha(t)$ e os perfis de pressão ao longo do plugue. O erro

entre a injetividade prevista e a medida (teste da Hipótese 3) é avaliado com as incertezas expandidas da medição e da previsão pelo erro normalizado E_n (Seção 6.7). As sequências de referência (reotimização míope e critério empírico) são comparadas à política no ambiente calibrado e, havendo ensaios adicionais em colaboração com o LRAP+, também em coreflood.

O resultado tecnológico é uma ferramenta computacional que integra o simulador físico, o modelo substituto, a PINN inversa, o ambiente de treinamento no padrão Gymnasium, os agentes treinados e o protocolo estatístico de avaliação, com uma interface de apoio à decisão que recebe os dados de água, rocha e operação de um poço e devolve a composição recomendada, com a incerteza associada. A arquitetura separará o módulo de avaliação do dano e da injetividade do módulo de decisão e especificará uma interface externa de troca de dados. Essa interface documentará entradas de composição química, condições de injeção e estado do reservatório, bem como saídas esperadas de desempenho de recuperação e restrições operacionais. Em eventual aplicação industrial, um modelo externo capaz de responder a alterações na composição da água poderá ser conectado à otimização para formular objetivos múltiplos ou restrições de recuperação. A especificação dessa interface será entregue no software; o acoplamento efetivo com simuladores proprietários, a otimização de EOR e sua validação não integram as metas deste projeto. O desenvolvimento segue práticas de engenharia de software (controle de versão, testes automatizados, integração contínua e documentação). A metodologia, as equações, os parâmetros identificados e o protocolo de avaliação serão publicados em artigos e na tese, com detalhamento suficiente para sua reprodução.

7. Metas, entregas verificáveis e indicadores de acompanhamento

7.1 Metas e entregas verificáveis

#	Meta / entrega	Indicador	Mês
M1	Base de dados integrada (águas, rocha, operação, injetividade)	≥ 300 registros com metadados completos e documentação	9
M2	Simulador radial multiespécie	Balanço de massa fechado em $\geq 99\%$; reprodução de casos da literatura	15
M3	Análise de sensibilidade global	Índices de Sobol para todos os parâmetros não medidos; conjunto mínimo de caracterização definido	18
M4	Parâmetros identificados por PINN inversa (teste da Hipótese 1)	Ensaio multietapas realizado (calibração com etapas iniciais e teste cego com etapas finais); erro na previsão cega de $\alpha \leq 15\%$	24
M5	Modelo substituto validado	$R^2 \geq 0{,}95$ em teste cego; avaliação $\geq 10^3\times$ mais rápida que o simulador	26
M6	Agente de RL robusto e comparado com as três referências (teste da Hipótese 2)	Ganho sobre a reotimização míope $\geq 5\%$ em ≥ 50 cenários de teste; correlação de Spearman da ordenação $\geq 0{,}8$	34
M7	Estimador do dano em operação	Separação entre dano e pressurização em dados de Volve; erro de previsão em janela futura $\leq 10\%$	38
M8	Validação da política em coreflood (teste da Hipótese 3)	Ensaio com a sequência do agente; α medida acima de $\alpha_{\min}$; erro do ambiente de simulação $\leq 15\%$	44
M9	Ferramenta de apoio à decisão	Ferramenta integrada e documentada; metodologia publicada em artigos e na tese	46
M10	Produção científica (Seção 9)	3 artigos submetidos a periódicos A1/A2 (P1–P3); 2 trabalhos completos apresentados no Rio Oil & Gas (C1) e em evento da SPE (C2)	20–46

7.2 Indicadores de acompanhamento

O acompanhamento acompanha os quatro relatórios parciais que condicionam a liberação das parcelas (item 8.4). Em cada relatório são verificadas as metas previstas para o período e indicadores de processo que mostram o avanço das atividades em curso, mesmo antes de a meta correspondente ser concluída.

Relatório	Metas a comprovar	Indicadores de processo
R1 (mês 12)	M1	Revisão sistemática concluída; simulador radial com módulo de incrustação implementado e balanço de massa verificado; plano experimental da campanha 1 definido pela análise de identificabilidade e ensaios iniciados; doutorando matriculado e iniciação científica selecionada; credenciamento no PEM; primeiros materiais de divulgação publicados

Relatório	Metas a comprovar	Indicadores de processo
R2 (mês 24)	M2, M3, M4	Ensaio da campanha 1 realizado e dados organizados; erro da previsão cega da Hipótese 1; primeira versão do modelo substituto; trabalho C1 apresentado; ações de divulgação acumuladas
R3 (mês 36)	M5, M6	Número de algoritmos triados e aprofundados; resultado estatístico da Hipótese 2 (IQM, probabilidade de melhoria); P1 e P2 submetidos; estimador aplicado aos dados de Volve; sequência e previsão da campanha 2 registradas antes do ensaio; exame de qualificação do doutorando; primeira proposta a edital externo submetida
RF (mês 48)	M7, M8, M9, M10	Resultado da campanha 2 (teste da Hipótese 3); C2 apresentado e P3 submetido; ferramenta de apoio à decisão integrada e documentada; tese em fase final; indicadores consolidados de divulgação (eventos, participantes, vídeos, acessos ao simulador)

Em todos os relatórios são informados também a execução orçamentária por elemento de despesa e o percentual de atividades do cronograma cumpridas no prazo.

8. Cronograma físico em meses corridos

O cronograma é contado a partir do início da execução; os relatórios parciais condicionam o desembolso de parcelas, conforme item 8.4. O detalhamento mensal será espelhado no plano de trabalho do SisFAPERJ. A Figura 2 apresenta as atividades mês a mês, com as metas (M), as publicações (C, P) e os relatórios parciais que condicionam as parcelas (R).

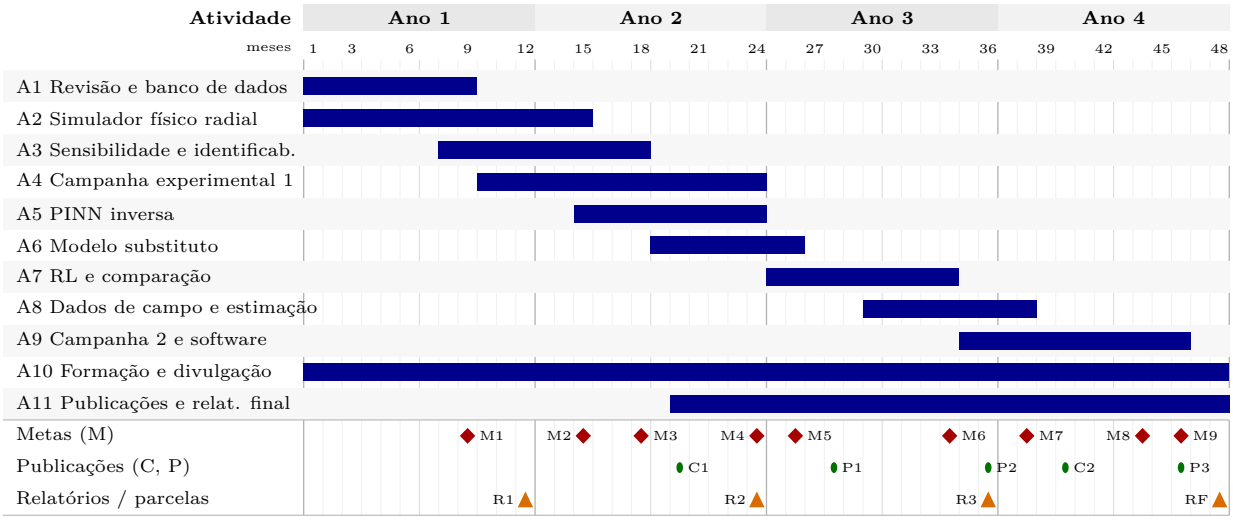


Figura 2: Cronograma físico mês a mês (48 meses de execução).

Atividade	Entrega / marco de acompanhamento	Meses
A1 Revisão sistemática e banco de dados	Base documentada, revisão e dados rastreáveis	1–9
A2 Simulador físico radial	Verificação, balanços e comparação bibliográfica	1–15
A3 Sensibilidade e identificabilidade	Morris, Sobol, plano experimental	8–18
A4 Campanha experimental 1	Calibração e teste cego de parâmetros	10–24
A5 PINN inversa	Estimação e incertezas	15–24
A6 Modelo substituto	Avaliação fora da amostra	19–26
A7 RL e comparação de estratégias	Comparação controlada e avaliação de segurança	25–34
A8 Dados de campo e estimação	Estudo de caso e análise de limitações	30–38
A9 Campanha 2 e software	Validação experimental e ferramenta integrada	35–46
A10 Formação e divulgação	Atividades educativas e relatórios	1–48
A11 Publicações e relatório final	Submissões em 20, 28, 36, 40 e 46; relatório final em 48	20–48

9. Resultados esperados

9.1 Resultados científicos

- Um simulador radial multiespécie do dano à formação que acopla incrustação, finos e argilas, filtração e dano biológico, e separa o dano da queda aparente de injetividade por pressurização do reservatório.

- Valores identificados, com incerteza, dos parâmetros que hoje entram como suposição nos modelos de injetividade (coeficientes de filtração e de dano, constantes cinéticas, salinidade e velocidade críticas), para as rochas e águas estudadas, e uma metodologia de identificação por PINN inversa validada em ensaios cegos (Hipótese 1).
- Uma hierarquia, obtida por análise de sensibilidade global, dos fatores de água, rocha e operação que mais afetam a injetividade e a decisão sobre a água, com um conjunto mínimo de caracterização por rocha.
- Evidência quantitativa sobre o valor da decisão sequencial na escolha da água de injeção (Hipótese 2): se, e em que condições, uma política que antecipa a evolução do dano supera a reotimização periódica e os critérios empíricos. Um resultado negativo também é informativo, pois indicaria que métodos estáticos mais simples são suficientes.
- Evidência experimental, em coreflood, de que as decisões obtidas no ambiente de simulação se sustentam no meio poroso real (Hipótese 3).

9.2 Resultados tecnológicos

- Uma ferramenta de apoio à decisão que recomenda a composição da água de injeção para um poço a partir de seus dados de água, rocha e operação, com a incerteza associada.
- Um protocolo de ensaios de coreflood para caracterização da sensibilidade de rochas à água de injeção, reutilizável em outros campos.
- Uma metodologia publicada, em artigos e na tese, que integra simulador, modelo substituto, PINN inversa, ambiente de treinamento e agentes, com protocolo de avaliação reprodutível.
- Curvas de decisão aplicáveis à operação, como o teor máximo de sulfato residual admissível em função do Ba^{2+} da água de formação e da vazão.

9.3 Formação e consolidação institucional

- Uma tese de doutorado no PEM/COPPE e orientações de iniciação científica na interface entre engenharia de petróleo, química de águas e inteligência artificial.
- Uma linha de pesquisa nova no programa, com base de dados, ferramenta computacional e protocolos experimentais que permanecem no grupo após o término do apoio.

9.4 Produção científica

Três artigos em periódicos A1 ou A2 e dois trabalhos completos em congressos, um no Rio Oil & Gas e um em evento da SPE. Cada publicação corresponde a uma etapa e a uma hipótese, de modo que a produção acompanha o avanço do projeto e a tese de doutorado se organiza como coletânea desses artigos.

Tipo	Tema e contribuição	Veículo pretendido	Mês
C1 Congresso	Simulador radial multiespécie, sensibilidade global e curvas de decisão do sulfato residual admissível para campos da Bacia de Campos (etapas 1–2)	Rio Oil & Gas Expo and Conference (IBP)	20
P1 Periódico A1/A2	Identificação por PINN inversa dos parâmetros não medidos do dano, com corefloods do LRAP+, análise de identificabilidade e incerteza segundo o GUM (Hipótese 1; etapas 3–4)	SPE Journal; Water Resources Research; Journal of Computational Physics	28
P2 Periódico A1/A2	Escolha da água de injeção como decisão sequencial sob incerteza: comparação estatística das famílias de RL com reotimização míope e critérios empíricos (Hipótese 2; etapa 5)	Engineering Applications of Artificial Intelligence; Applied Energy; Geoenergy Science and Engineering	36
C2 Congresso	Separação entre dano e pressurização em dados de campo (Volve) e avaliação da política em histórico real de injeção (etapa 6)	SPE International Conference on Formation Damage Control ou SPE ATCE	40
P3 Periódico A1/A2	Validação experimental em coreflood de políticas de RL para a água de injeção: sequência de composições do agente e erro do ambiente de simulação (Hipótese 3; etapa 7)	SPE Journal; Geoenergy Science and Engineering; Fuel	46

Os meses indicam a submissão. A classificação A1/A2 de cada periódico será conferida na avaliação Qualis vigente no momento da submissão.

10. Riscos técnico-científicos e estratégias de mitigação

Risco	Mitigação	Nível
Poucos dados de injetividade com composição medida	Dados sintéticos calibrados em ensaios próprios; Volve	Alto
Parâmetros do dano não identificáveis com os dados disponíveis	Análise de identificabilidade antes dos ensaios; tomadas de pressão intermediárias; ensaio em múltiplas etapas; incerteza propagada ao agente	Médio
Dificuldade de treino da PINN em frentes abruptas	Ponderação adaptativa, treino progressivo no tempo; comparação com calibração clássica sobre o simulador	Médio
Modelos biológicos pouco validados	Tratar como módulo opcional; ensaios dedicados	Médio
Custo computacional do treinamento de RL	Modelo substituto; GPU dedicada	Médio

Risco	Mitigação	Nível
Política de RL fora do domínio físico válido	RL com restrições e filtro de segurança; verificação no simulador completo	Médio
Diferença entre o ambiente de simulação e o meio poroso real	Calibração na campanha 1, ajuste do agente ao ambiente em escala de laboratório e previsão registrada antes do ensaio da campanha 2	Médio
Acesso a testemunhos e águas reais	Plugs de afloramento análogos e salmouras sintéticas de composição controlada; caracterização no LRAP+	Médio
Efeito dos aditivos não ensaiado em coreflood	Efeito dos aditivos parametrizado a partir da literatura; validação em ensaios adicionais com o LRAP+, quando viabilizados	Médio
Número reduzido de ensaios contratados	Ensaio em múltiplas etapas no mesmo plugue; desenho orientado pela análise de identificabilidade; ensaios adicionais em colaboração com o LRAP+, quando viabilizados	Médio

11. Formação de recursos humanos

- Uma bolsa CAPES de doutorado (48 meses). A tese se divide naturalmente em duas partes: na primeira metade, desenho dos ensaios e identificação de parâmetros por PINN inversa (etapa 3); na segunda, modelo substituto e agente de RL (etapas 4 e 5). O credenciamento do proponente como orientador no PEM será concluído antes da indicação do bolsista (item 8.12.1.1), prevista para os 3 primeiros meses de vigência. Perfil desejado: graduação e mestrado em Engenharia Mecânica, com conhecimento de programação em Python; experiência em ensaios laboratoriais com água de produção será considerada um diferencial.
- Duas iniciações científicas (FAPERJ e PIBIC/UFRJ) e projetos de fim de curso em Engenharia Mecânica e de Petróleo: ensaios (etapa 3), desenvolvimento do software (etapa 7) e simulador de divulgação.

12. Infraestrutura existente e necessária

12.1 Infraestrutura existente

Os ensaios de coreflood serão realizados no LRAP+ (COPPE/UFRJ), conforme proposta comercial LRAP-P20261030, com a seguinte infraestrutura:

- sistema de coreflood HPHT para injeção de salmouras em plugs de rocha, com monitoramento de vazão e de pressões absoluta e diferencial, incluindo tomadas intermediárias por capilares ao longo do plugue;
- poropermeâmetro Weatherford DV-4000 para porosidade e permeabilidade absoluta;
- infraestrutura para preparação e caracterização de salmouras e fluidos.

12.2 Infraestrutura necessária

Estação de trabalho com GPU dedicada ao treinamento dos modelos substitutos e dos agentes de RL, que demandam milhares de episódios de simulação, e duas campanhas de ensaios no LRAP+ (Seção 19).

13. Redes e colaborações nacionais e internacionais

O projeto se apoia em uma rede já estabelecida pelo proponente ao longo de mais de dois anos de atuação na COPPE/UFRJ:

- **LRAP+ (COPPE/UFRJ)**, coordenado pelo Prof. Paulo Couto: execução dos ensaios de coreflood e caracterização petrofísica, já formalizada pela proposta comercial LRAP-P20261030, com possibilidade de ensaios adicionais em colaboração.
- **LabMEMS (PEM/COPPE/UFRJ)**, liderado pelos Profs. Renato M. Cotta e Carolina P. Naveira-Cotta: grupo em que o proponente desenvolve o pós-doutorado, com produção conjunta em água de produção; colaboração na modelagem de fenômenos de transporte e nos métodos numéricos do simulador físico (etapa 1).
- **Programa de Engenharia Mecânica (COPPE/UFRJ)**: interação com os grupos de mecânica computacional e de fenômenos de transporte em meios porosos, e integração do doutorando e dos alunos de iniciação científica ao programa.
- **Dados abertos de campo**: conjunto Volve, disponibilizado pela Equinor, e dados públicos da ANP, usados na etapa 6.

A partir dos resultados, essa rede permite propor projetos com operadoras das Bacias de Campos e de Santos financiados pela cláusula de P,D&I da ANP (Seção 16.5).

14. Impacto esperado e público beneficiado

14.1 Impacto científico, tecnológico, social, econômico e ambiental

- **Científico:** uma formulação nova para a escolha da água de injeção, como decisão sequencial sob incerteza com o dano à formação como dinâmica do sistema; valores identificados, com incerteza metrológica, de parâmetros que a literatura trata como ajuste empírico; e uma comparação estatisticamente controlada de famílias de RL em um problema de engenharia de reservatórios, com protocolo reprodutível.

- **Tecnológico e econômico:** menor frequência de intervenções corretivas (acidificação, *scale squeeze*, *workover*), menor consumo elétrico de bombeamento pela menor sobrepressão de injeção, especificação da composição da água ajustada a cada poço em vez de limites genéricos, e manutenção da reposição de volume que sustenta a recuperação de óleo.
- **Ambiental:** maior reaproveitamento da água produzida por reinjeção, menor descarte no mar, dosagem de inibidores e biocidas ajustada à necessidade real e menor consumo de energia por metro cúbico injetado.
- **Social:** formação de pessoas qualificadas no Estado do Rio de Janeiro na interface entre engenharia de petróleo, química de águas e inteligência artificial, com um doutorado, iniciações científicas e projetos de fim de curso; essa qualificação amplia a empregabilidade dos egressos na cadeia de óleo e gás fluminense e em setores que demandam IA aplicada. Os materiais de divulgação (Seção 17) aproximam o público geral da ciência e da engenharia ligadas à principal atividade econômica do Estado.

14.2 Público beneficiado e impacto institucional

- **Público beneficiado:** operadoras de campos offshore e empresas de serviços de tratamento de água e estimulação; a ANP e órgãos ambientais, por meio de critérios técnicos para reinjeção; grupos de pesquisa em engenharia de petróleo e em IA aplicada; e estudantes de graduação e pós-graduação da UFRJ.
- **Institucional:** uma linha de pesquisa nova no PEM/COPPE, com base de dados, protocolos experimentais e ferramenta computacional que permanecem no grupo após o apoio.

15. Contribuição para o desenvolvimento do Estado do Rio de Janeiro

O Rio de Janeiro é um polo central da produção nacional de petróleo, nas Bacias de Campos e de Santos, e boa parte dela vem de campos maduros sob injeção de água ou de campos do pré-sal em que a reinjeção de água produzida cresce com o corte de água. A incrustação por $BaSO_4$ é o problema dominante nos históricos operacionais da Bacia de Campos [7, 15], e prolongar a vida útil desses campos tem efeito direto sobre os royalties e participações especiais que sustentam parte relevante das receitas do Estado e dos municípios produtores. O projeto contribui ao produzir conhecimento e ferramentas aplicáveis a esses campos, ao formar no Estado pessoal qualificado na interface entre engenharia de petróleo e inteligência artificial, demandado pela cadeia de óleo e gás fluminense, e ao fortalecer a capacidade de pesquisa da COPPE/UFRJ em um tema com potencial de cooperação com as empresas sediadas no Rio de Janeiro. A reinjeção de água produzida também se alinha às metas de redução de descarte de efluentes no mar.

16. Estratégia de integração e fixação institucional

16.1 Inserção na instituição executora

O proponente já atua no Programa de Engenharia Mecânica da COPPE/UFRJ como pesquisador de pós-doutorado há mais de dois anos, o que assegura a inserção imediata no programa, o conhecimento de seus grupos e laboratórios e a continuidade das colaborações iniciadas nesse período. Com o apoio do PROFIX-RJ, o proponente atuará no Programa de Engenharia Mecânica da COPPE/UFRJ, com os ensaios experimentais conduzidos na infraestrutura do LRAP+ (Seção 12), e com a estação de trabalho adquirida pelo projeto incorporada ao patrimônio da UFRJ.

16.2 Linha de pesquisa a ser criada

Inteligência artificial informada por física para injeção de água e dano à formação, reunindo modelagem do dano, identificação de parâmetros, aprendizado por reforço e validação experimental em meios porosos.

16.3 Infraestrutura disponibilizada

A COPPE/UFRJ disponibilizará ao proponente posto de trabalho no Programa de Engenharia Mecânica, com acesso à rede institucional e às instalações básicas (energia elétrica e água), condições que já lhe são oferecidas como pós-doutorando, além do acesso às bibliotecas da UFRJ e ao Portal de Periódicos CAPES. Os ensaios experimentais serão realizados no LRAP+ (Seção 12). A capacidade computacional necessária ao treinamento dos modelos não é suprida pela infraestrutura atual e é solicitada neste projeto (Seção 19); a estação de trabalho será incorporada ao patrimônio da UFRJ e permanecerá disponível ao grupo após o término do apoio.

16.4 Integração ao Programa de Pós-Graduação

Credenciamento como orientador no PEM antes da indicação do bolsista CAPES de doutorado; orientação da tese vinculada ao projeto; coorientação de dissertações e de iniciação científica.

16.5 Plano de sustentabilidade após o término do apoio

A base de dados, o simulador, o protocolo de ensaios e o software formam uma plataforma que viabiliza propostas a editais da FAPERJ (Jovem Cientista do Nosso Estado, Apoio a Grupos Emergentes), ao CNPq (Universal, Produtividade em Pesquisa) e projetos com a indústria financiados pela cláusula de investimento em P,D&I da ANP. A primeira proposta externa será submetida até o terceiro ano do projeto.

17. Plano de educação, comunicação, popularização e divulgação científica

O plano traduz uma pergunta concreta, *por que a água que entra em um poço de petróleo precisa ser escolhida com cuidado?*, para públicos não especializados, e acompanha o cronograma (atividade A10):

Ação (item 2.20)	Descrição	Público e meta
Espaços de ciência e eventos (II, VI)	Participação na Semana Nacional de Ciência e Tecnologia e em atividades abertas da UFRJ, com o infográfico do projeto e o simulador interativo	Público geral
Materiais audiovisuais (III)	Vídeos curtos sobre água produzida, incrustação e IA na indústria	Redes sociais; 6 vídeos
Atividades digitais (IV, VII)	Simulador interativo na web, em que o visitante escolhe a água e vê a injetividade cair ou se manter	Público geral e estudantes de graduação
Comunicação pública (V)	Textos de divulgação e entrevistas sobre os resultados, em linguagem acessível	Imprensa e público geral

O bolsista de doutorado e os alunos de iniciação científica participam das ações, como parte da formação. O alcance é acompanhado por indicadores simples (número de eventos, participantes, visualizações e acessos ao simulador) e relatado nos relatórios parciais.

18. Estratégia de acesso, preservação e difusão dos resultados

A difusão dos resultados será feita por meio de publicações em periódicos científicos internacionais e de apresentações em congressos da área, conforme o plano de produção científica da Seção 9: três artigos em periódicos A1 ou A2 e dois trabalhos completos, um na Rio Oil & Gas Expo and Conference e outro em evento da Society of Petroleum Engineers (SPE). Cada publicação corresponde a uma etapa e a uma hipótese do projeto, de modo que a metodologia, os parâmetros identificados com suas incertezas e o protocolo de avaliação sejam descritos com detalhamento suficiente para sua reprodução. O conjunto dos resultados será consolidado na tese de doutorado, depositada no repositório institucional da UFRJ, o que assegura sua preservação e acesso permanente.

19. Orçamento detalhado e justificado

Os valores correspondem às propostas comerciais anexadas na aba "Orçamento Detalhado": proposta nº 10615/2026-B da CEL Tecnologia e Informática Ltda. (CNPJ 03.621.548/0001-47), de 30/10/2026, para a estação de trabalho, e proposta LRAP-P20261030 do LRAP+/COPPE/UFRJ, de 30/10/2026, para os ensaios de injetividade. As demais cotações exigidas pelo item 9.6.1 permanecem em posse do proponente.

Capital. A estação de trabalho é necessária ao treinamento dos modelos computacionais do projeto: as PINNs em formulação inversa (etapa 3), os operadores neurais usados como modelo substituto (etapa 4) e os agentes de aprendizado por reforço (etapa 5), que exigem milhares de episódios de simulação e a execução de múltiplas sementes por algoritmo. A GPU de 96 GB permite manter em memória, simultaneamente, o modelo substituto, os lotes de treinamento e os ambientes paralelos do agente, e o uso dedicado ao longo dos 48 meses viabiliza as campanhas de treinamento e as repetições exigidas pelo protocolo estatístico (Seção 6). Os demais componentes foram dimensionados para alimentar a GPU sem gargalo (processador de 16 núcleos, 128 GB de memória, armazenamento NVMe e fonte compatível com a potência do conjunto) e para proteger o equipamento contra falhas de energia durante treinamentos longos (nobreak). O equipamento será incorporado ao patrimônio da UFRJ.

Custeio. Os ensaios de injetividade no LRAP+ fornecem os dados experimentais para a identificação dos parâmetros do dano (etapa 3, Hipótese 1) e para a validação experimental da política (etapa 7, Hipótese 3). O teclado e o mouse da estação de trabalho são classificados como material de consumo.

Grupo	Item	Qtd.	Unit. (R$)	Total (R$)
Capital – estação de trabalho (proposta CEL nº 10615/2026-B; etapas 3 a 5)				
	Placa de vídeo NVIDIA RTX PRO 6000 Blackwell Max-Q Workstation Edition, 96 GB GDDR7 ECC (PNY)	1	146.845,00	146.845,00
	Processador AMD Ryzen 9 9950X3D2, 16 núcleos/32 *threads*	1	7.138,00	7.138,00
	Refrigeração líquida Corsair iCUE Link H150i, 360 mm	1	1.050,00	1.050,00
	Placa-mãe Gigabyte X870M Aorus Elite WiFi7 (AM5)	1	2.289,00	2.289,00
	Memória Kingston Fury Beast 128 GB (2 × 64 GB) DDR5 5600 MHz	1	16.905,00	16.905,00
	SSD WD Black SN8100 4 TB NVMe PCIe Gen5	1	6.028,00	6.028,00
	Gabinete ATX Redragon Pulse	1	523,00	523,00
	Kit de 4 ventiladores 12 cm Round5 Aurora	1	195,00	195,00
	Fonte Thermaltake Toughpower TF3 1650 W, 80 Plus Titanium	1	3.675,00	3.675,00
	Monitor AOC U27P2 27” 4K IPS	1	2.034,00	2.034,00
	Nobreak TS Shara 3000 VA	1	5.235,00	5.235,00
	Desconto comercial da proposta			−2.215,00
			Subtotal capital	189.702,00
Custeio – serviços de terceiros, pessoa jurídica (proposta LRAP-P20261030; etapas 3 e 7)				
	Análise de injetividade em plugues de afloramento com monitoramento das pressões diferencial e absoluta	2	5.000,00	10.000,00
Custeio – material de consumo (proposta CEL nº 10615/2026-B)				
	Kit teclado e mouse sem fio Logitech MK540	1	298,00	298,00
			Subtotal custeio	10.298,00
	Total			**200.000,00**

20. Ética, integridade, biossegurança, propriedade intelectual e dados de pesquisa

- **Ética e integridade:** o projeto não envolve seres humanos, animais nem acesso ao patrimônio genético. Os ensaios seguem as normas de segurança do LRAP+ para fluidos pressurizados e o descarte de salmouras e reagentes segue os procedimentos da UFRJ.
- **Dados de terceiros:** usados conforme suas licenças (Volve: CC BY-NC-SA 4.0, uso não comercial; dados da ANP: dados abertos), com citação da fonte.
- **Plano de gestão de dados:** dados brutos de ensaios, metadados de cada ensaio (amostra, fluidos, condições, instrumentos e certificados de calibração), códigos e modelos versionados em repositório privado, com cópia de segurança institucional.
- **Propriedade intelectual:** eventuais direitos de propriedade intelectual decorrentes do projeto observarão a Lei nº 9.279/1996, o Marco Legal de CT&I e o item 12.20 do edital.

Referências

[1] F. Macedonio, A. Ali, T. Poerio, E. El-Sayed, E. Drioli, and M. Abdel-Jawad. Direct contact membrane distillation for treatment of oilfield produced water. *Separation and Purification Technology*, 126:69–81, 2014.

[2] T. El-badawy, M. H. D. Othman, T. Matsuura, M. R. Bilad, M. R. Adam, Z. S. Tai, J. Ravi, A. F. Ismail, M. A. Rahman, J. Jaafar, J. Usman, and T. A. Kurniawan. Progress in treatment of oilfield produced water using membrane distillation and potentials for beneficial re-use. *Separation and Purification Technology*, 278:119494, 2021.

[3] Y. Liang, Y. Ning, L. Liao, and B. Yuan. Special focus on produced water in oil and gas fields: Origin, management, and reinjection practice. In *Formation Damage During Improved Oil Recovery: Fundamentals and Applications*, pages 515–586. Gulf Professional Publishing, 2018.

[4] M. S. Kamal, I. Hussein, M. Mahmoud, A. S. Sultan, and M. A. S. Saad. Oilfield scale formation and chemical removal: A review. *Journal of Petroleum Science and Engineering*, 171:127–139, 2018.

[5] A. B. Bin Merdhah, A. A. M. Yassin, and M. A. Muherei. Laboratory and prediction of barium sulfate scaling at high-barium formation water. *Journal of Petroleum Science and Engineering*, 70(1–2):79–88, 2010.

[6] P. G. Bedrikovetsky, E. J. Mackay, R. M. P. Silva, F. M. R. Patricio, and F. F. Rosário. Produced water re-injection with seawater treated by sulphate reduction plant: Injectivity decline, analytical model. *Journal of Petroleum Science and Engineering*, 68(1–2):19–28, 2009.

[7] A. A. Rocha, M. Frydman, S. A. B. da Fontoura, F. F. Rosário, and M. C. M. Bezerra. Numerical modeling of salt precipitation during produced water reinjection. In *SPE International Symposium on Oilfield Scale*, Aberdeen, United Kingdom, 2001. SPE-68336-MS.

[8] R. Miri and H. Hellevang. Salt precipitation during CO_2 storage – a review. *International Journal of Greenhouse Gas Control*, 51:136–147, 2016.

[9] M. Kamalipour, S. A. Mousavi Dehghani, A. Naseri, and S. Abbasi. Role of agitation and temperature on calcium sulfate crystallization in water injection process. *Journal of Petroleum Science and Engineering*, 151:362–372, 2017.

[10] K. C. Khilar and H. S. Fogler. The existence of a critical salt concentration for particle release. *Journal of Colloid and Interface Science*, 101(1):214–224, 1984.

[11] S. Pang and M. M. Sharma. A model for predicting injectivity decline in water-injection wells. *SPE Formation Evaluation*, 12(3):194–201, 1997.

[12] O. R. Pal and N. S. Al-Ghamdi. Integrated analysis approach of water and solids for root cause of injectivity decline of water injection well – a case study. *Geoenergy Science and Engineering*, 231:212351, 2023.

[13] H. M. Kermani, M. Bonto, and H. M. Nick. Chemical solutions for restoring scaling-induced injectivity impairment in offshore produced water re-injection. *Science of the Total Environment*, 903:166597, 2023.

[14] A. Shabani, A. Kalantariasl, M. Parvazdavani, and S. Abbasi. Geochemical and hydrodynamic modeling of permeability impairment due to composite scale formation in porous media. *Journal of Petroleum Science and Engineering*, 176:1071–1081, 2019.

[15] M. C. M. Bezerra, F. F. Rosário, A. A. Rocha, and C. L. Sombra. Assessment of scaling tendency of Campos Basin fields based on the characterization of formation waters. In *SPE International Symposium on Oilfield Scale*, Aberdeen, United Kingdom, 2004. SPE-87452-MS.

[16] Aftab Hussain Arain, Ahmad Salam Farooqi, and Rayed S. Alshareef. Advancing low-salinity waterflooding for improved oil recovery: Mechanisms, machine learning, and future directions. *Petroleum Research*, 2026. Article in press; accepted 30 July 2026.

[17] Ali Shafiei, Afshin Tatar, Mahsheed Rayhani, Madiyar Kairat, and Ingkar Askarova. Artificial neural network, support vector machine, decision tree, random forest, and committee machine intelligent system help to improve performance prediction of low salinity water injection in carbonate oil reservoirs. *Journal of Petroleum Science and Engineering*, 219:111046, 2022.

[18] A. Tatar, I. Askarova, A. Shafiei, and M. Rayhani. Data-driven connectionist models for performance prediction of low salinity waterflooding in sandstone reservoirs. *ACS Omega*, 6:32304–32326, 2021.

[19] J. Kondori, M. I. Miah, S. Zendehboudi, F. Khan, and D. Heagle. Hybrid connectionist models to assess recovery performance of low salinity water injection. *Journal of Petroleum Science and Engineering*, 197:107833, 2021.

[20] Leonardo Fonseca Reginato, Rafael dos Santos Gioria, and Marcio Augusto Sampaio. Hybrid machine learning for modeling the relative permeability changes in carbonate reservoirs under engineered water injection. *Energies*, 16(13):4849, 2023.

[21] Diana Mercado Sierra, Argenis Alvarez Rojas, and Victor Salazar Araque. Low-salinity water-injection optimization in the namorado field using compositional simulation and artificial intelligence, 2020. SPE 198995; ver tambem resumo no Journal of Petroleum Technology, doi:10.2118/0920-0065-JPT.

[22] Razieh Khosravi, Mohammad Simjoo, and Mohammad Chahardowli. A new insight into pilot-scale development of low-salinity polymer flood using an intelligent-based proxy model coupled with particle swarm optimization. *Scientific Reports*, 14, 2024.

[23] Shibao Yuan, Jia Song, Fengxiang Yang, Haiyan Jiang, and Zihan Ren. Research on the connectivity between injection and production wells in the hongqian in situ combustion project in xinjiang based on machine learning. *Engineering Applications of Artificial Intelligence*, 172:114337, 2026.

[24] Y. Nasir and L. J. Durlofsky. Deep reinforcement learning for optimal well control in subsurface systems with uncertain geology, 2022. arXiv:2203.13375.

[25] R. Abdalla, N. Agban, C. Lüddeke, D. Sui, and P. Jaeger. Multi agent physics informed reinforcement learning for waterflooding optimization. *Franklin Open*, 10:100229, 2025.

[26] Jinzhao Hu, Deli Jia, Shichu Liu, Wenchang Wang, and Fushen Ren. Research on intelligent regulation of layered water injection based on reinforcement learning SAC algorithm. *Scientific Reports*, 15:33044, 2025.

[27] Li Jin, Jingpan Bai, and Botao Liu. Reinforcement learning-based dynamic optimization strategy of WAG flooding with inter-well connectivity for high water-cut reservoirs. *Processes*, 14(19):3089, 2026.

[28] Chaodong Tan, Chunqiu Wang, Jinjie Tian, Huizhao Niu, Qi Wei, and Xiongying Zhang. Optimization of profile control and oil displacement scheme parameters based on deep deterministic policy gradient. *ACS Omega*, 8:23739–23753, 2023.

[29] Aída Álvarez Díez, Rocío Pena Rois, Iulian Mocanu, Claudia Orzan, Cristian Brebenel, J. Stere, S. Muíños Landín, and J. M. Fernández Montenegro. Reinforcement learning-based DSS for coagulant and disinfectant dosage selection on drinking water treatment plants. *Water Supply*, 24(1):86–102, 2024.

[30] Y. Zhang, D. Meng, and W. Ma. Model-based reinforcement learning for chemical dosing optimization in a municipal wastewater treatment plant: A comparative study of three actor–critic algorithms. *Processes*, 14:1800, 2026.

[31] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.

[32] James R. Bulau and M. Matt Honarpour. A quality control program in core analysis. In *International Symposium of the Society of Core Analysts*, Calgary, Canada, 1997. SCA-9713.

[33] J. D. Jansen, S. G. Douma, D. R. Brouwer, P. M. J. Van den Hof, O. H. Bosgra, and A. W. Heemink. Closed-loop reservoir management. In *SPE Reservoir Simulation Symposium*, The Woodlands, Texas, USA, 2009. SPE-119098-MS.

[34] P. Bedrikovetsky, D. Marchesin, F. Shecaira, A. L. Souza, P. V. Milanez, and E. Rezende. Characterisation of deep bed filtration system from laboratory pressure drop measurements. *Journal of Petroleum Science and Engineering*, 32(2–4):167–177, 2001.

[35] G. H. Nancollas and S. T. Liu. Crystal growth and dissolution of barium sulfate. *SPE Journal*, 15(6):509–516, 1975.

[36] M. D. Morris. Factorial sampling plans for preliminary computational experiments. *Technometrics*, 33(2):161–174, 1991.

[37] I. M. Sobol'. Global sensitivity indices for nonlinear mathematical models and their Monte Carlo estimates. *Mathematics and Computers in Simulation*, 55(1–3):271–280, 2001.

[38] O. Fuks and H. A. Tchelepi. Limitations of physics informed machine learning for nonlinear two-phase transport in porous media. *Journal of Machine Learning for Modeling and Computing*, 1(1):19–37, 2020.

[39] L. Lu, P. Jin, G. Pang, Z. Zhang, and G. E. Karniadakis. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3:218–229, 2021.

[40] Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart, and A. Anandkumar. Fourier neural operator for parametric partial differential equations. In *International Conference on Learning Representations (ICLR)*, 2021.

[41] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2 edition, 2018.

[42] S. A. A. Rizvi and A. Pertzborn. Development of a bias compensating Q-learning controller for a multi-zone HVAC facility. *IEEE/CAA Journal of Automatica Sinica*, 10(8), 2023.

[43] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.

[44] Will Dabney, Mark Rowland, Marc G. Bellemare, and Rémi Munos. Distributional reinforcement learning with quantile regression. In *AAAI Conference on Artificial Intelligence*, 2018.

[45] X. Fang, G. Gong, G. Li, L. Chun, P. Peng, W. Li, X. Shi, and X. Chen. Deep reinforcement learning optimal control strategy for temperature setpoint real-time reset in multi-zone building HVAC system. *Applied Thermal Engineering*, 212:118552, 2022.

[46] J. Achiam, D. Held, A. Tamar, and P. Abbeel. Constrained policy optimization. In *International Conference on Machine Learning (ICML)*, pages 22–31, 2017.

[47] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *International Conference on Machine Learning (ICML)*, 2015.

[48] A. Centurelli, L. Arleo, A. Rizzo, S. Tolu, C. Laschi, and E. Falotico. Closed-loop dynamic control of a soft manipulator using deep reinforcement learning. *IEEE Robotics and Automation Letters*, 7(2):4741–4748, 2022.

[49] A. Ray, J. Achiam, and D. Amodei. Benchmarking safe exploration in deep reinforcement learning. Technical report, OpenAI, 2019.

[50] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International Conference on Machine Learning (ICML)*, pages 1861–1870, 2018.

[51] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms, 2017. arXiv:1707.06347.

[52] A. Silvestri, D. Coraci, S. Brandi, A. Capozzoli, E. Borkowski, J. Köhler, D. Wu, M. N. Zeilinger, and A. Schlueter. Real building implementation of a deep reinforcement learning controller to enhance energy efficiency and indoor temperature control. *Applied Energy*, 368:123447, 2024.

[53] M. Janner, J. Fu, M. Zhang, and S. Levine. When to trust your model: Model-based policy optimization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.

[54] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. In *International Conference on Learning Representations (ICLR)*, 2020.

[55] M. Ye and A. H. Elsheikh. Model-based reinforcement learning for active flow control. *Physics of Fluids*, 37(9):093363, 2025.

[56] Tabish Rashid, Mikayel Samvelyan, Christian Schroeder de Witt, Gregory Farquhar, Jakob Foerster, and Shimon Whiteson. QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *International Conference on Machine Learning (ICML)*, 2018.

[57] B. Yun, J. Shim, J. Moon, S. Lee, K. Jeong, and K. H. Cho. Towards autonomous operation of two-stage reverse osmosis water treatment system with multi-agent reinforcement learning. *Desalination*, 609:118870, 2025.

[58] Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[59] Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations (ICLR)*, 2022.

[60] A. Nair, A. Gupta, M. Dalal, and S. Levine. AWAC: Accelerating online reinforcement learning with offline datasets, 2020. arXiv:2006.09359.

[61] Richard S. Sutton, Doina Precup, and Satinder Singh. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1–2):181–211, 1999.

[62] O. Nachum, S. Gu, H. Lee, and S. Levine. Data-efficient hierarchical reinforcement learning. In *Advances in Neural Information Processing*

Systems (NeurIPS), 2018.
[63] X. Yang, Z. Ji, J. Wu, Y.-K. Lai, C. Wei, G. Liu, and R. Setchi. Hierarchical reinforcement learning with universal policies for multistep robotic manipulation. *IEEE Transactions on Neural Networks and Learning Systems*, 33(9):4727–4741, 2022.
[64] JCGM. Evaluation of measurement data – guide to the expression of uncertainty in measurement (JCGM 100:2008). Technical report, Joint Committee for Guides in Metrology, 2008.
[65] JCGM. Evaluation of measurement data – supplement 1 to the GUM: Propagation of distributions using a Monte Carlo method (JCGM 101:2008). Technical report, Joint Committee for Guides in Metrology, 2008.
[66] B. Lakshminarayanan, A. Pritzel, and C. Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
[67] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, New York, 1993.
[68] L. Yang, X. Meng, and G. E. Karniadakis. B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data. *Journal of Computational Physics*, 425:109913, 2021.
[69] A. Raue, C. Kreutz, T. Maiwald, J. Bachmann, M. Schilling, U. Klingmüller, and J. Timmer. Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood. *Bioinformatics*, 25(15):1923–1929, 2009.
[70] ISO. ISO 13528:2022 – statistical methods for use in proficiency testing by interlaboratory comparison, 2022. International Organization for Standardization, Genebra.
[71] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger. Deep reinforcement learning that matters. In *AAAI Conference on Artificial Intelligence*, pages 3207–3214, 2018.
[72] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
[73] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.
[74] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.